Fundação Getulio Vargas
Escola de Matemática Aplicada

Sávio Vinícius Costa do Amaral

Estratégia de Arbitragem Estatística Neutra ao Mercado Baseada em Fatores de PCA e Reversão à Média

Rio de Janeiro
2026

Sávio Vinícius Costa do Amaral

Estratégia de Arbitragem Estatística Neutra ao Mercado Baseada em Fatores de PCA e Reversão à Média

Dissertação submetida à Escola de Matemática Aplicada como requisito parcial para a obtenção do grau de Mestre em Matemática Aplicada e Ciência de Dados.

Área de estudo: Finanças Quantitativas

Orientador: Rodrigo dos Santos Targino

Rio de Janeiro
2026

Agradecimentos

Agradeço, primeiramente, à minha família, pelo apoio incondicional ao longo de toda a minha trajetória. Foram eles que estiveram presentes nos momentos mais desafiadores, oferecendo suporte, incentivo e confiança, tornando possível a realização deste trabalho.

Aos meus professores, expresso minha profunda gratidão por todos os ensinamentos que contribuíram para minha formação acadêmica e pessoal. Agradeço não apenas aos docentes do mestrado e da graduação, mas também aos professores da minha cidade natal, que foram fundamentais na construção das bases que me trouxeram até aqui.

Aos amigos que fiz ao longo dessa jornada, meu muito obrigado pela parceria, pelas trocas de conhecimento e pelos momentos compartilhados, que tornaram esse percurso mais leve e significativo. Por fim, agradeço a todos que, de alguma forma, contribuíram para a concretização deste trabalho.

Resumo

O objetivo desta dissertação é desenvolver, implementar e avaliar empiricamente uma estratégia de arbitragem estatística neutra ao mercado baseada em fatores extraídos por Análise de Componentes Principais (PCA) e modelagem de reversão à média. Especificamente, propõe-se: (i) decompor os retornos acionários em componentes sistemáticos e idiossincráticos por meio de fatores principais; (ii) modelar os resíduos como processos de Ornstein–Uhlenbeck, permitindo a construção de indicadores de desalinhamento relativo; e (iii) implementar uma estratégia long–short com neutralização explícita das exposições fatoriais, avaliando seu desempenho fora da amostra sob custos de transação realistas.

Os resultados empíricos indicam que a estratégia apresenta desempenho consistente no mercado brasileiro tanto no curto quanto no longo prazo, sugerindo a persistência de estruturas de reversão à média nos componentes idiossincráticos. Em contraste, no mercado norte-americano, embora se observem resultados positivos no curto prazo, há deterioração significativa de desempenho no longo prazo, evidenciando limitações da abordagem nesse mercado.

Adicionalmente, foram investigadas extensões metodológicas, incluindo número adaptativo de fatores, limiares dinâmicos baseados em quantis e procedimentos de otimização de hiperparâmetros. Apesar de melhorias pontuais, tais adaptações não foram suficientes para restaurar de forma consistente o desempenho no longo prazo no mercado americano.

Em conjunto, os resultados destacam tanto o potencial quanto as limitações de estratégias de arbitragem estatística baseadas em reversão à média, enfatizando a importância da adaptabilidade e do alinhamento entre o horizonte de calibração e a dinâmica dos sinais explorados.

Abstract

This dissertation develops, implements, and empirically evaluates a market-neutral statistical arbitrage strategy based on Principal Component Analysis (PCA) factors and mean-reversion dynamics. The proposed framework decomposes stock returns into systematic and idiosyncratic components using PCA, models the residuals as Ornstein–Uhlenbeck processes, and constructs long–short portfolios with explicit factor neutrality. Trading signals are generated through standardized deviations (s-scores), capturing temporary dislocations relative to equilibrium levels.

Empirical results reveal that the strategy exhibits strong performance in the Brazilian market across both short and long horizons, suggesting the persistence of mean-reverting behavior in idiosyncratic components. In contrast, in the U.S. market, although the strategy performs well in the short term, its performance deteriorates significantly over longer horizons, indicating reduced effectiveness in that market.

Several methodological extensions are explored, including adaptive selection of principal components, dynamic thresholding based on empirical quantiles, and hyperparameter optimization. While these approaches yield improvements in specific settings, they fail to consistently restore long-term out-of-sample performance in the U.S. market.

Overall, the findings highlight both the potential and the limitations of PCA-based statistical arbitrage strategies. In particular, they emphasize the importance of market structure, parameter stability, and the alignment between calibration horizons and the underlying dynamics of trading signals. These results point to the need for more adaptive and robust frameworks in future research on quantitative trading strategies.

Sumário

1 Introdução **7**

2 Revisão da Literatura **8**
2.1 Arbitragem Estatística e Fundamentos Teóricos 8
2.2 Pairs Trading e Cointegração 8
2.3 Avanços Recentes e Modelos de Alta Dimensionalidade 9

3 Análise de Componentes Principais (PCA) **10**
3.1 Abordagem PCA na Construção dos Fatores 12
3.2 Construção e retorno dos eigenportfólios 14

4 Modelo de valor relativo baseado em fatores principais de PCA **15**
4.1 Formulação contínua do modelo 15
4.2 O Processo de Ornstein–Uhlenbeck como modelo para desvios idiossincráticos 16
4.3 Componente idiossincrático e hipótese de reversão à média . . 17

5 Estratégia **18**
5.1 Cálculo do s-score 19
5.2 Regras de corte e definição de sinais 20
5.3 Esquema de pesos iguais por lado 22
5.4 Neutralidade ao mercado 23
5.5 Hedge multifatorial 24
5.6 Visão Geral da Estratégia 26

6 Cálculo do PnL **27**

7 Resultados do Backtest **29**
7.1 Análise de Curto Prazo 30
7.2 Análise de Longo Prazo 39
7.3 Otimização no Horizonte de Longo Prazo 42

8 Melhorias sugeridas **47**

9 Conclusão **50**

10 Referências **52**

11 Apêndices **54**

A Processo de Ornstein–Uhlenbeck: cálculo e estimação dos parâmetros **54**

A.1 Discretização em tempo e modelo AR(1) 57

B s-score **61**

C Evolução dos Parâmetros Otimizados **62**

1 Introdução

A arbitragem estatística, ou *Statistical Arbitrage* (StatArb), constitui um dos pilares da indústria de investimentos quantitativos moderna, sendo amplamente empregada por bancos de investimento, hedge funds e plataformas algorítmicas de alta complexidade (AVELLANEDA; LEE, 2008). Em contraste com abordagens discricionárias baseadas em análise fundamentalista, estratégias de StatArb são guiadas por sinais sistemáticos, regras explícitas e modelos matemáticos que procuram identificar e explorar ineficiências temporárias nos preços de ativos financeiros. Tais estratégias têm evoluído de métodos puramente estatísticos e econométricos para estruturas que incorporam técnicas de aprendizado de máquina e modelos de alta dimensionalidade (GUIJARRO-ORDONEZ; PELGER; ZANOTTI, 2022).

O princípio que sustenta a arbitragem estatística é a geração de retornos excessivos a partir de divergências transitórias entre ativos que, historicamente, apresentam relações estáveis. Assume-se que tais relações tendem a se restabelecer ao longo do tempo, tornando possível explorar estruturas de reversão à média e padrões de desequilíbrios momentâneos. Nesse contexto, esta dissertação contribui ao avaliar uma estratégia de arbitragem estatística neutra ao mercado baseada em fatores principais extraídos por Análise de Componentes Principais (PCA) e modelagem de reversão à média.

A pesquisa desenvolvida busca: (i) decompor retornos acionários em fatores sistemáticos e idiossincráticos; (ii) modelar os resíduos como processos estocásticos de reversão à média; e (iii) construir portfólios long–short neutros ao mercado capazes de explorar oportunidades de arbitragem estatística no mercado acionário norte-americano. A abordagem proposta visa integrar rigor estatístico, neutralidade ao mercado e eficiência computacional, alinhando-se às diretrizes metodológicas mais recentes da literatura quantitativa.

Nos capítulos seguintes é discutido a base teórica da modelagem por PCA, depois é descrito como os fatores principais são utilizados para extrair e modelar os componentes residuais de cada ativo, depois é calculado os sinais de reversão à média e, por fim, apresentam-se a análise empírica do desempenho da estratégia.

2 Revisão da Literatura

A literatura sobre arbitragem estatística constitui um corpo extenso e diversificado, abrangendo desde abordagens clássicas de *pairs trading* até modelos avançados baseados em fatores condicionais e aprendizado profundo. Esta seção apresenta um panorama das principais contribuições relevantes para esta dissertação.

2.1 Arbitragem Estatística e Fundamentos Teóricos

O conceito de arbitragem estatística dialoga diretamente com a Hipótese dos Mercados Eficientes (EMH), segundo a qual os preços dos ativos refletem toda a informação disponível. Em contraste, estratégias de StatArb partem da premissa de que desvios temporários e previsíveis podem surgir devido ao comportamento estocástico dos preços, permitindo capturar oportunidades de reversão (GATEV; GOETZMANN; ROUWENHORST, 2006; VIDYAMURTHY, 2004). Formalmente, Hogan et al. (HOGAN et al., 2004) definem uma estratégia de StatArb como um portfólio autossustentado, de custo inicial nulo, com expectativa assintoticamente positiva de retorno e probabilidade assintótica nula de perdas.

2.2 Pairs Trading e Cointegração

Entre as classes mais tradicionais de StatArb encontra-se o *pairs trading*. Desde o estudo seminal de Gatev, Goetzmann e Rouwenhorst (GATEV; GOETZMANN; ROUWENHORST, 2006), sabe-se que ativos economicamente semelhantes apresentam movimentos conjuntos, sendo possível explorar desvios temporários por meio de posições *long–short*. Avellaneda e Lee (AVELLANEDA; LEE, 2008) formalizam esse mecanismo utilizando modelos de cointegração e processos estacionários para o resíduo cointegrado, estabelecendo o arcabouço moderno para estratégias de reversão à média.

Modelos estocásticos, como o processo de Ornstein–Uhlenbeck, tornaram-se ferramentas fundamentais para representar spreads cointegrados e otimizar limiares operacionais (BERTRAM, 2010; ELLIOTT; HOEK; MALCOLM, 2005; ZENG; LEE, 2014). Estudos recentes, como Göncü e Akyildirim (GÖNCÜ; AKYILDIRIM, 2016), demonstram que, sob determinadas condições, um spread modelado como processo OU satisfaz formalmente critérios de arbitragem estatística.

2.3 Avanços Recentes e Modelos de Alta Dimensionalidade

A literatura recente trata a arbitragem estatística como um problema composto por três elementos: (i) construção de portfólios replicadores; (ii) extração de sinais temporais; e (iii) alocação ótima do portfólio. Nesse sentido, Guijarro-Ordonez, Pelger e Zanotti (GUIJARRO-ORDONEZ; PELGER; ZANOTTI, 2022) apresentam uma abordagem inovadora ao integrar aprendizado profundo, filtragem temporal e modelos de fatores (incluindo PCA e IPCA). Os autores mostram que resíduos fatoriais bem construídos tendem a ser aproximadamente estacionários, constituindo excelente base para extração de sinais de reversão e destacando que o componente idiossincrático é primordial para o desempenho em StatArb.

A presente dissertação dialoga diretamente com estas vertentes ao explorar o uso de fatores de PCA na construção de portfólios residuais e na aplicação de modelos estocásticos de reversão à média em um contexto de neutralidade ao mercado.

3 Análise de Componentes Principais (PCA)

A Análise de Componentes Principais (PCA) é uma técnica estatística amplamente utilizada para reduzir a dimensionalidade de conjuntos de dados multivariados mantendo, tanto quanto possível, a variabilidade original (STANKOVIć et al., 2021; WANG et al., 2022). Em essência, o PCA projeta as variáveis observadas em um novo sistema de coordenadas formado por combinações lineares não correlacionadas, denominadas componentes principais. Esses componentes são ordenados de modo que o primeiro capture a maior parcela da variância total, o segundo capture a maior fração da variância remanescente, e assim sucessivamente.

A motivação central por trás do PCA é a identificação de estruturas latentes nos dados. Quando as variáveis originais exibem correlação significativa, é possível que uma parte substancial da informação seja explicada por poucas direções principais. Assim, o PCA atua como um mecanismo eficiente para condensar informações redundantes, contribuindo para o enfrentamento de problemas como sobreajuste, multicolinearidade e complexidade excessiva dos modelos (ANDERSEN, 2007). Em aplicações que envolvem alto número de covariáveis, essa redução é particularmente útil, pois facilita a interpretação dos padrões estruturais e diminui o risco de instabilidade nos ajustes estatísticos.

Do ponto de vista algébrico, considera-se um conjunto de p variáveis padronizadas, $X_1, X_2, \ldots, X_p$, com matriz de covariância amostral C. O PCA consiste em resolver o problema de autovalores

$$Cv_j = \lambda_j v_j, \tag{1}$$

onde v_j representa o j-ésimo autovetor associado ao autovalor λ_j. Cada autovetor define uma direção no espaço das variáveis originais, enquanto cada autovalor corresponde à variância explicada por essa direção. A j-ésima componente principal é dada pela combinação linear

$$Z_j = v_{1j}X_1 + v_{2j}X_2 + \cdots + v_{pj}X_p. \tag{2}$$

Os vetores v_j são escolhidos de modo que os componentes principais satisfaçam três propriedades fundamentais: (i) são ortogonais entre si e, consequentemente, não correlacionados; (ii) cada componente Z_j maximiza a variância dentre todas as combinações lineares de norma unitária que são

ortogonais às componentes principais anteriores, isto é, Z_j resolve um problema de otimização restrito em que se impõe ortogonalidade em relação a $Z_1, \ldots, Z_{j-1}$; (iii) os autovetores são normalizados, isto é, $\|v_j\| = 1$, garantindo uma escala bem definida.

Essa construção é equivalente à solução do problema de otimização

$$\max_{v} \quad v^\top C v \quad \text{sujeito a} \quad \|v\| = 1, \tag{3}$$

cuja solução é dada pelo autovetor associado ao maior autovalor de C. As componentes subsequentes são obtidas de forma análoga, adicionando-se a restrição de ortogonalidade em relação às direções previamente encontradas (TABACHNICK; FIDELL, 2012).

Um aspecto importante na aplicação prática do PCA é a escolha do número de componentes a ser retido. Estudos aplicados utilizam critérios como o percentual acumulado de variância explicada, geralmente buscando capturar entre 80% e 90% da variância total (WANG et al., 2022). Esse processo evita tanto a inclusão de ruído quanto a perda excessiva de informação relevante. Graficamente, pode-se empregar o *scree plot*, enquanto métodos mais formais incluem critérios de Kaiser ou análises baseadas na distribuição dos eigenvalues.

A ortogonalidade entre as componentes é uma das principais vantagens do PCA. Como cada componente explica uma parcela distinta da variância, a técnica elimina explicitamente a redundância entre variáveis e produz fatores livres de correlação, o que é vantajoso em modelos que dependem de estabilidade e parcimônia. No entanto, é importante ressaltar que o PCA exige padronização prévia das variáveis, pois características com variância elevada podem influenciar de forma desproporcional a decomposição, introduzindo vieses indesejados (KUMAR, 2019).

No contexto desta dissertação, o PCA desempenha papel essencial ao decompor os retornos acionários em fatores sistemáticos e idiossincráticos. Os primeiros componentes principais capturam movimentos amplos do mercado e efeitos setoriais, enquanto os componentes de ordem superior tendem a refletir variabilidade específica de cada ativo. Assim, ao remover os fatores dominantes e trabalhar com os resíduos fatoriais, obtém-se uma série temporal mais próxima de estacionária, adequada para modelagem de reversão à média e construção de portfólios de arbitragem estatística. Essa abordagem permite reduzir exposição sistemática, aumentar a neutralidade de mercado e melhorar a qualidade dos sinais utilizados nas estratégias quantitativas

subsequentes.

3.1 Abordagem PCA na Construção dos Fatores

A extração de fatores por meio da Análise de Componentes Principais (PCA) constitui a base da modelagem desenvolvida nesta dissertação. O objetivo é decompor os retornos acionários em combinações lineares ortogonais que capturam os principais movimentos sistemáticos do mercado, utilizando exclusivamente informação histórica de preços. Essa abordagem segue a formulação clássica apresentada em Jolliffe (2002) e encontra ampla aplicação em modelos quantitativos baseados em fatores.

Matriz de retornos e janela móvel

Seja

$$R = (R_{t,i})_{1\le t\le T,\, 1\le i\le N} \in \mathbb{R}^{T\times N},$$

a matriz de retornos diários, onde cada linha representa uma data e cada coluna um ativo. Para cada data t, reestima-se o PCA sobre uma janela móvel de M observações,

$$R^{(t)} = R_{t-M:t-1} \in \mathbb{R}^{M\times N},$$

preservando apenas os retornos mais recentes. Essa escolha evita que a estrutura de correlação seja afetada por informações excessivamente antigas e permite que os fatores reflitam condições de mercado dinâmicas.

Padronização dos ativos

Como diferentes ativos apresentam volatilidades distintas, é necessário padronizar cada coluna da janela. Para o ativo i, definimos

$$\mu_i^{(t)} = \frac{1}{M}\sum_{k=1}^{M} R_{k,i}^{(t)} \quad , \qquad \sigma_i^{(t)} = \sqrt{\frac{1}{M-1}\sum_{k=1}^{M}\left(R_{k,i}^{(t)} - \mu_i^{(t)}\right)^2}.$$

A matriz padronizada $\widetilde{R}^{(t)}$ é dada por

$$\widetilde{R}_{k,i}^{(t)} = \frac{R_{k,i}^{(t)} - \mu_i^{(t)}}{\sigma_i^{(t)}},$$

de modo que cada ativo possui média zero e variância unitária dentro da janela. Essa etapa garante que o PCA identifique fatores associados à estrutura de correlação e não a diferenças de escala.

Matriz de correlação

Construímos a matriz de correlação empírica entre ativos:

$$\rho_{ij}^{(t)} = \frac{1}{M-1} \sum_{k=1}^{M} \widetilde{R}_{k,i}^{(t)} \, \widetilde{R}_{k,j}^{(t)},$$

ou de forma matricial,

$$\rho^{(t)} = \frac{1}{M-1} (\widetilde{R}^{(t)})^{\top} \widetilde{R}^{(t)}.$$

A matriz $\rho^{(t)}$ é simétrica e definida positiva, contendo toda a informação sobre movimentos conjuntos entre os ativos no período recente.

Decomposição PCA da matriz de correlação

Aplica-se o PCA sobre $\rho^{(t)}$ resolvendo o problema espectral

$$\rho^{(t)} v_j^{(t)} = \lambda_j^{(t)} v_j^{(t)}, \qquad j = 1, \ldots, N,$$

com autovalores ordenados, ou seja,

$$\lambda_1^{(t)} \geq \lambda_2^{(t)} \geq \cdots \geq \lambda_N^{(t)} \geq 0.$$

Os maiores autovalores correspondem a direções que explicam a maior parcela da variância conjunta dos ativos. Assim,

- o primeiro componente geralmente representa o *fator de mercado*, pois captura um movimento comum a praticamente todos os ativos;
- componentes seguintes capturam padrões setoriais, temáticos ou estruturais;
- autovalores pequenos formam o *bulk spectrum*, típico de ruído.

Essa propriedade permite interpretar o PCA como um filtro que separa a estrutura sistemática dos movimentos idiossincráticos.

3.2 Construção e retorno dos eigenportfólios

Cada autovetor v_j obtido pelo PCA define uma direção no espaço dos retornos e, portanto, uma combinação linear entre os ativos. Para interpretar essa direção como um portfólio negociável, é necessário expressar essa combinação diretamente em termos dos retornos originais.

Observe que a j-ésima componente principal pode ser escrita como uma combinação linear das séries de retornos ajustadas pela escala dos ativos, isto é,

$$Z_j(t) = \sum_{i=1}^{N} v_{j,i}^{(t)} \frac{R_{t,i}}{\sigma_i^{(t)}}.$$

Reorganizando os termos, obtém-se

$$Z_j(t) = \sum_{i=1}^{N} \left(\frac{v_{j,i}^{(t)}}{\sigma_i^{(t)}} \right) R_{t,i}.$$

Essa representação mostra que a componente principal pode ser interpretada como o retorno de um portfólio cujos pesos são dados por

$$q_{j,i}^{(t)} = \frac{v_{j,i}^{(t)}}{\sigma_i^{(t)}}.$$

onde $\sigma_i^{(t)}$ denota o desvio-padrão do ativo i na janela de estimação.

Essa expressão mostra que os pesos do portfólio são obtidos ajustando os coeficientes do autovetor pela volatilidade dos ativos, de modo que ativos mais voláteis recebem menor exposição. Dessa forma, o vetor $q_j^{(t)}$ pode ser interpretado como uma carteira que replica a direção associada ao j-ésimo componente principal no espaço dos retornos.

O vetor $q_j^{(t)}$ define o chamado *eigenportfólio* associado ao j-ésimo autovalor, isto é, um portfólio sintético cuja dinâmica é predominantemente explicada pelo j-ésimo componente principal.

Retornos fatoriais

O retorno do j-ésimo fator no instante t é dado pelo retorno do respectivo eigenportfólio:

$$F_j(t) = \sum_{i=1}^{N} q_{j,i}^{(t)} R_{t,i} = R_{t,\cdot} \cdot q_j^{(t)}.$$

Equivalentemente, pode-se escrever

$$F_j(t) = \sum_{i=1}^{N} \frac{v_{j,i}^{(t)}}{\sigma_i^{(t)}} R_{t,i},$$

mostrando que os retornos fatoriais são combinações lineares dos retornos individuais ponderadas pelos autovetores ajustados pela volatilidade.

Os fatores obtidos em diferentes ordens são ortogonais entre si, o que facilita a decomposição dos retornos em componente sistemática e idiossincrática. Nesta dissertação foi utilizado janelas móveis de $M = 60$ dias.

A separação entre variação sistemática (capturada pelos fatores) e variação específica (resíduos) é essencial para estratégias de arbitragem estatística, pois frequentemente os resíduos apresentam comportamento mais estacionário.

4 Modelo de valor relativo baseado em fatores principais de PCA

Um modelo de valor relativo é um modelo que avalia ativos comparando seu preço/retorno a benchmarks, pares ou fatores, buscando identificar desvios temporários da relação histórica entre eles. Nesta seção, é apresentado o modelo de valor relativo utilizado para a precificação de ações a partir de retornos *excessivos* em relação a um conjunto de fatores sistemáticos. A formulação segue de perto a abordagem proposta por (AVELLANEDA; LEE, 2008), que usa fatores de risco construídos via Análise de Componentes Principais (PCA) obtidos diretamente da matriz de retornos das ações da amostra.

A ideia central é modelar o retorno de cada ação como a soma de dois componentes: (i) uma parte *sistemática*, explicada por um pequeno número de fatores comuns (os componentes principais), e (ii) um componente *idiossincrático*, que captura desvios específicos da ação em relação ao comportamento médio do mercado (ou do conjunto de ações) e que será explorado pela estratégia de arbitragem estatística.

4.1 Formulação contínua do modelo

Utilizaremos notação em tempo contínuo para descrever o modelo. Denote por $S_i(t)$ o preço da ação $i \in \{1, \ldots, N\}$ no instante t, medido em anos a

partir de uma data inicial arbitrária. Denote por $F_k(t)$, com $k = 1, \ldots, K$, os *retornos instantâneos* dos fatores principais obtidos via PCA. Assumimos que os retornos instantâneos das ações satisfazem o sistema de equações diferenciais estocásticas

$$\frac{dS_i(t)}{S_i(t)} \;=\; \alpha_i\, dt \;+\; \sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt \;+\; dX_i(t), \qquad i = 1, \ldots, N, \tag{4}$$

onde:

- $\sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt$ é o componente sistemático do retorno da ação i, explicado pelos fatores principais de PCA;
- α_i é o *drift idiossincrático* da ação i, interpretado como a taxa média de retorno em excesso em relação à combinação de fatores;
- $dX_i(t)$ é o incremento de um processo estocástico estacionário que representa as flutuações idiossincráticas em torno da trajetória ditada pelos fatores.

A carga de risco da ação i ao fator k é capturada pelo coeficiente β_{ik}.

4.2 O Processo de Ornstein–Uhlenbeck como modelo para desvios idiossincráticos

Uma vez definida a estrutura multifatorial do retorno na Eq. (4), é necessário especificar a dinâmica estocástica do componente idiossincrático. Para capturar desvios transitórios em relação ao nível implícito pelos fatores de PCA, é adotado o processo de Ornstein–Uhlenbeck (O–U), amplamente utilizado na literatura de arbitragem estatística (AVELLANEDA; LEE, 2008).

O processo O–U é definido pela equação diferencial estocástica

$$dX_i(t) = \kappa_i\,(m_i - X_i(t))\, dt + \sigma_i\, dW_i(t), \tag{5}$$

onde $\kappa_i > 0$ é a velocidade de reversão à média, m_i é o nível de equilíbrio de longo prazo do processo, σ_i é a difusão, e $W_i(t)$ é um movimento browniano padrão.

Este processo apresenta três propriedades essenciais que o faz ser uma boa proposta:

1. **Estacionaridade**: para $\kappa_i > 0$, o processo possui distribuição estacionária normal com média m_i e variância $\sigma_i^2/(2\kappa_i)$, permitindo interpretar desvios de $X_i(t)$ em relação a m_i como anomalias temporárias em relação ao valor de equilíbrio.

2. **Reversão à média**: quando $X_i(t)$ está distante de m_i, o termo determinístico $\kappa_i(m_i - X_i(t))$ induz uma força restauradora, característica fundamental para modelos de valor relativo.

3. **Linearidade e estimabilidade**: a versão discretizada do processo é equivalente a um modelo AR(1), o que permite estimar os parâmetros $(\kappa_i, m_i, \sigma_i)$ diretamente por regressão linear simples, facilitando a implementação empírica.

Além disso, a reversão à média é uma característica essencial para capturar a dinâmica típica de spreads de arbitragem estatística. Choques específicos de curto prazo, como fluxos temporários, efeitos de liquidez ou ajustes idiossincráticos, produzem deslocamentos que tendem a se dissipar ao longo do tempo, comportamento que é descrito precisamente pelo termo restaurador $\kappa_i(m_i - X_i(t))$.

Do ponto de vista empírico, a discretização do processo O–U é equivalente a um modelo AR(1), que se ajusta de forma robusta aos resíduos resultantes da regressão multifatorial. Assim, o modelo combina simplicidade analítica e facilidade de estimação: os parâmetros $(\kappa_i, m_i, \sigma_i)$ podem ser obtidos por regressão linear simples, e a estrutura resultante permite medir o desvio relativo de cada ativo por meio de estatísticas padronizadas, como o s-score, utilizadas diretamente na construção dos sinais de trading.

Todas as etapas de obtenção dessas expressões, desde a solução do processo, passando pelo cálculo da média e variância estacionárias, até os procedimentos de estimação dos parâmetros são apresentadas de forma detalhada no **Apêndice A**

4.3 Componente idiossincrático e hipótese de reversão à média

Retomando o modelo da Eq. (4), o termo

$$\alpha_i \, dt + dX_i(t)$$

representa a parcela do retorno da ação que não é explicada pelos fatores principais extraídos via PCA. Interpreta-se esse termo como o componente idiossincrático do ativo.

O parâmetro α_i descreve a tendência média de retorno em excesso da ação em relação aos fatores. Já o processo $X_i(t)$ mede o desvio instantâneo do preço relativo da ação em relação ao nível sugerido pelos fatores sistemáticos. Desvios persistentes em $X_i(t)$ são interpretados como deslocamentos temporários de preço, oriundos de choques de liquidez, sobre-reação ou fluxos específicos da ação.

Como discutido na Seção 4.2, assumimos que $X_i(t)$ segue um processo de Ornstein–Uhlenbeck, o que implica que tais desvios tendem a retornar a um nível de equilíbrio m_i ao longo do tempo. Assim, a hipótese fundamental é que o preço relativo apresenta uma componente transiente que, ao se afastar muito do equilíbrio, sinaliza oportunidades de arbitragem estatística.

Em síntese, o componente idiossincrático fornece o elo entre (i) o modelo multifatorial baseado em PCA e (ii) a geração de sinais de reversão utilizados na estratégia empírica de valor relativo.

5 Estratégia

Nesta seção é descrito a estratégia de arbitragem estatística construída a partir do modelo de valor relativo apresentado na Seção 4. Recordando brevemente os elementos essenciais do modelo utilizado. Seja $S_i(t)$ o preço da ação $i \in \{1, \ldots, N\}$ no instante t. De acordo com o modelo multifatorial em tempo contínuo descrito na Eq. (4), o retorno da ação satisfaz esse sistema de equação diferencial estocástica

$$\frac{dS_i(t)}{S_i(t)} \;=\; \alpha_i\, dt \;+\; \sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt \;+\; dX_i(t), \tag{6}$$

onde $F_k(t)$ denota o retorno do k-ésimo fator principal de PCA, β_{ik} é a sensibilidade da ação i a esse fator, α_i é o retorno médio em excesso e $X_i(t)$ descreve o desvio idiossincrático em relação ao nível implícito pelos fatores.

Assumimos que $X_i(t)$ segue um processo de Ornstein–Uhlenbeck conforme Eq. (5):

$$dX_i(t) = \kappa_i\,(m_i - X_i(t))\, dt + \sigma_i\, dW_i(t), \tag{7}$$

com $\kappa_i > 0$, $m_i \in \mathbb{R}$, $\sigma_i > 0$ e $W_i(t)$ um movimento browniano padrão. Nesse enquadramento, m_i representa o nível de equilíbrio de longo prazo do desvio idiossincrático e κ_i quantifica a velocidade com que a ação tende a reverter a esse nível após choques transitórios.

A estratégia explorará desvios significativos entre $X_i(t)$ e m_i, devidamente padronizados, para definir sinais de compra e venda.

5.1 Cálculo do s-score

O s-score é um indicador adimensional que mede o quão distante o processo idiossincrático $X_i(t)$ se encontra de seu nível de equilíbrio, em unidades de desvio-padrão estacionário. Seguindo a literatura de arbitragem estatística, considera-se a distribuição estacionária do processo O–U na Eq. (7), para $\kappa_i > 0$, essa distribuição é normal com média m_i e variância $\mathrm{Var}[X_i(\infty)] = \dfrac{\sigma_i^2}{2\kappa_i}$, como é mostrado no Apêndice A

Portanto, o desvio-padrão de equilíbrio é definido como

$$\sigma_{i,\mathrm{eq}} = \sqrt{\frac{\sigma_i^2}{2\kappa_i}}.$$

O s-score da ação i no instante t é dado por

$$s_i(t) = \frac{X_i(t) - m_i}{\sigma_{i,\mathrm{eq}}}. \tag{8}$$

Valores elevados (em módulo) de $s_i(t)$ indicam que a ação se encontra em uma região estatisticamente rara, quando comparada à distribuição de equilíbrio implícita pelo processo O–U. Assim, por construção:

- $s_i(t) \gg 0$ sugere que o preço relativo da ação está *supervalorizado* em relação ao equilíbrio;
- $s_i(t) \ll 0$ sugere que o preço relativo está *subvalorizado*.

Na implementação discreta, $X_i(t)$ é estimado a partir de resíduos $\varepsilon_i(\tau)$ da regressão multifatorial em janelas deslizantes, e os parâmetros $(\kappa_i, m_i, \sigma_i)$ são obtidos via ajuste de um modelo AR(1) equivalente, conforme discutido anteriormente. O s-score constitui, portanto, o elo entre a dinâmica estocástica idiossincrática e a regra de trading.

5.2 Regras de corte e definição de sinais

A estratégia utiliza o s-score como estatística central para detectar desvios significativos em relação ao nível de equilíbrio implícito pelo processo de Ornstein–Uhlenbeck. Com base nesses desvios, definimos regras de entrada e saída que exploram a hipótese de reversão à média.

Para evitar operar em regiões dominadas por ruído, pequenos deslocamentos estatisticamente irrelevantes, introduzimos quatro parâmetros de corte, distintos para abertura e encerramento de posições:

$$s_{\mathrm{bo}} < 0, \qquad s_{\mathrm{so}} > 0, \qquad s_{\mathrm{bc}} > 0, \qquad s_{\mathrm{sc}} < 0,$$

onde:

- s_{bo} (*buy-to-open*) é o limiar negativo para abertura de posições compradas;
- s_{so} (*sell-to-open*) é o limiar positivo para abertura de posições vendidas;
- s_{bc} (*buy-to-close*) é o limiar positivo para encerramento de posições vendidas;
- s_{sc} (*sell-to-close*) é o limiar negativo para encerramento de posições compradas.

Dessa forma, o conjunto de regras de negociação pode ser escrito como:

$$\text{abrir compra se } s_i(t) < s_{\mathrm{bo}}, \qquad \text{abrir venda se } s_i(t) > s_{\mathrm{so}},$$

$$\text{fechar compra se } s_i(t) > s_{\mathrm{sc}}, \qquad \text{fechar venda se } s_i(t) < s_{\mathrm{bc}}.$$

Os valores numéricos dos limiares de decisão foram inicialmente fixados de acordo com os parâmetros propostos em (AVELLANEDA; LEE, 2008). Posteriormente, esses valores foram refinados por meio de uma abordagem adaptativa baseada em quantis empíricos da distribuição do s-score, permitindo ajustar dinamicamente os pontos de entrada e saída às condições recentes de mercado.

A motivação para restringir a abertura de posições a valores extremos do s-score decorre diretamente da interpretação do processo idiossincrático. Como discutido na Seção 4.2, $X_i(t)$ deve oscilar em torno de um equilíbrio

m_i, e grandes desvios são eventos relativamente raros sob a distribuição estacionária. Assim, ao abrir posições apenas quando $s_i(t)$ excede um limiar suficientemente elevado, a estratégia foca nos episódios com potenciais oportunidades de reversão à média.

Por outro lado, o encerramento das posições é ativado quando o s-score retorna para valores próximos de zero (em torno dos cortes s_{bc} e s_{sc}). Essa regra é coerente com a dinâmica prevista pelo processo de Ornstein–Uhlenbeck: em equilíbrio, espera-se que a maior parte do tempo $X_i(t)$ permaneça próxima de sua média. Assim, fechar posições quando $s_i(t)$ retorna à região central captura a reversão esperada, ao mesmo tempo que evita manter posições excessivamente longas em um regime em que o sinal já perdeu valor preditivo.

A lógica subjacente é, portanto, detectar ações cujos desvios idiossincráticos se afastaram de maneira estatisticamente significativa do equilíbrio, abrir posições apostando na reversão desses desvios, e encerrá-las quando o processo retornar a uma vizinhança neutra. Esse ciclo de entrada e saída está intimamente ligado à *escala temporal de reversão* do processo de O–U, frequentemente caracterizada pelo parâmetro $\tau_i = 1/\kappa_i$, interpretado como o tempo característico para o retorno ao equilíbrio.

Em suma, os cortes traduzem a dinâmica de reversão à média em regras de negociação disciplinadas, garantindo que a estratégia opere apenas diante de desvios estatisticamente relevantes e seja encerrada quando o sinal perde significância.

A partir das regras de corte, cada ativo é classificado no instante t como candidato a compra, venda ou sem posição:

comprar se $s_i(t) < s_{\mathrm{bo}}$, vender se $s_i(t) > s_{\mathrm{so}}$, caso contrário, sem posição.

Isso define dois conjuntos de ativos:

$$\mathcal{L}(t) = \{i : s_i(t) < s_{\mathrm{bo}}\}, \qquad \mathcal{S}(t) = \{i : s_i(t) > s_{\mathrm{so}}\},$$

correspondentes aos sinais positivos (*long*) e negativos (*short*). Em termos de sinal bruto,

$$\tilde{w}_i(t) = \begin{cases} +1, & i \in \mathcal{L}(t), \\ -1, & i \in \mathcal{S}(t), \\ 0, & \text{caso contrário.} \end{cases}$$

No entanto, tais sinais precisam ser convertidos em pesos financeiros que controlem a exposição da carteira

5.3 Esquema de pesos iguais por lado

As regras de corte descritas na Seção 5.2 produzem, a cada instante t, um conjunto de ativos com posições compradas e vendidas, de acordo com a magnitude e o sinal do desvio idiossincrático medido pelo s-score. Para transformar esses sinais discretos em um portfólio financeiro, é necessário especificar como o capital será distribuído entre os ativos selecionados.

Adota-se um esquema de *pesos iguais por lado*, no qual a totalidade do capital alocado no bloco comprado e no bloco vendido é distribuída uniformemente entre os ativos pertencentes a cada conjunto. Seja

$$\mathcal{L}(t) = \{i : s_i(t) < s_{\text{bo}}\}, \qquad \mathcal{S}(t) = \{i : s_i(t) > s_{\text{so}}\},$$

correspondendo, respectivamente, aos sinais de compra e de venda. Os pesos são definidos como:

$$w_i(t) = \frac{1}{|\mathcal{L}(t)|}, \qquad i \in \mathcal{L}(t), \tag{9}$$

$$w_i(t) = -\frac{1}{|\mathcal{S}(t)|}, \qquad i \in \mathcal{S}(t), \tag{10}$$

$$w_i(t) = 0, \qquad \text{caso contrário.} \tag{11}$$

Isso garante que:

$$\sum_{i \in \mathcal{L}(t)} w_i(t) = 1, \qquad \sum_{i \in \mathcal{S}(t)} w_i(t) = -1,$$

tornando a carteira estritamente *neutra*: a exposição comprada compensa exatamente a exposição vendida, e a posição líquida em valor é nula, ou seja, $\sum w_i(t) = 0$.

A escolha por pesos iguais por lado é motivada por duas razões principais:

1. **Evitar concentração indevida.** A normalização uniforme impede que a carteira seja dominada por poucos ativos com s-scores extremos, promovendo uma distribuição equilibrada do risco e garantindo que a estratégia explore um conjunto diversificado de oportunidades de reversão à média.

2. **Neutralidade direcional em valor.** Ao impor uma exposição comprada de $+1$ e uma exposição vendida de -1, a estratégia não carrega nenhuma aposta sistemática em relação ao movimento agregado

do mercado. Movimentos amplos no índice tendem a impactar long e short de maneira simétrica, de modo que o rendimento líquido decorra principalmente da dinâmica relativa entre os ativos, exatamente a fonte de retorno que a metodologia busca explorar.

Esse esquema de pesos estabelece a base estrutural para que, nas etapas seguintes, possa-se impor neutralidade em relação aos fatores sistemáticos por meio de um *hedge* multifatorial.

5.4 Neutralidade ao mercado

A etapa anterior introduziu o esquema de pesos iguais por lado, no qual a exposição comprada totaliza $+1$ e a exposição vendida totaliza -1, resultando em uma carteira essencialmente *neutra*. Essa é a primeira camada de neutralização necessária em uma estratégia long–short de valor relativo, pois garante que o portfólio não carregue, em termos de valor, nenhuma aposta direcional explícita em relação ao mercado agregado.

No entanto, a neutralidade em valor é apenas uma condição preliminar. Mesmo com $\sum_i w_i(t) = 0$, o portfólio pode permanecer sensível aos fatores sistemáticos que explicam grande parte da covariância entre os retornos, como os componentes principais extraídos por PCA. Em outras palavras, diferenças estruturais entre os ativos comprados e vendidos podem gerar *beta líquido* não nulo.

Para que a estratégia seja uma verdadeira arbitragem estatística, isto é, para que seu desempenho reflita exclusivamente a dinâmica idiossincrática associada à reversão à média, é necessário impor neutralidade aos fatores sistemáticos.

A ideia de neutralidade ao mercado pode ser formalizada a partir de um modelo multifatorial clássico. Suponha que o retorno do ativo i seja dado por

$$R_i(t) = \sum_{j=1}^{m} \beta_{ij}(t)\, F_j(t) + \tilde{R}_i(t), \tag{12}$$

onde $F_j(t)$ são fatores sistemáticos (fatores extraídos via PCA) e $\tilde{R}_i(t)$ é o componente idiossincrático. Seja $w_i(t)$ o peso do ativo i no portfólio em t; o retorno da carteira é então

$$R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, R_i(t). \tag{13}$$

Substituindo (12), obtemos

$$
\begin{aligned}
R^{\text{port}}(t) &= \sum_{i=1}^{N} w_i(t) \left[\sum_{j=1}^{m} \beta_{ij}(t)\, F_j(t) + \tilde{R}_i(t) \right] \\
&= \sum_{j=1}^{m} \left[\sum_{i=1}^{N} w_i(t)\, \beta_{ij}(t) \right] F_j(t) + \sum_{i=1}^{N} w_i(t)\, \tilde{R}_i(t). \qquad (14)
\end{aligned}
$$

Definimos a *exposição agregada* do portfólio ao fator j como

$$
\beta_j^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, \beta_{ij}(t). \qquad (15)
$$

Um portfólio é *market-neutral* (ou, mais geralmente, *factor-neutral*) quando suas projeções sobre os fatores são nulas, isto é,

$$
\beta_j^{\text{port}}(t) = 0, \qquad j = 1, \ldots, m. \qquad (16)
$$

Nessas condições, a decomposição (14) se reduz a

$$
R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, \tilde{R}_i(t), \qquad (17)
$$

ou seja, o retorno da carteira passa a depender exclusivamente dos componentes idiossincráticos $\tilde{R}_i(t)$.

Esse resultado esclarece por que a neutralidade ao mercado é central em estratégias baseadas em reversão à média: se o portfólio carregasse beta residual em relação a algum fator $F_j(t)$, parte de seu desempenho poderia ser explicada por movimentos amplos do mercado ou de fatores setoriais, e não pela dinâmica de reversão dos resíduos. Em outras palavras, o portfólio deixaria de ser uma aposta puramente relativa e passaria a incorporar, de forma não controlada, risco sistemático.

5.5 Hedge multifatorial

Como discutido na Seção 5.4, um portfólio long–short pode satisfazer $\sum_i w_i(t) = 0$ e, ainda assim, apresentar betas agregados não nulos em relação aos fatores extraídos via PCA. Seja, para cada data t,

$$
w(t) = \big(w_1(t), \ldots, w_N(t)\big)
$$

o vetor de pesos da carteira sobre as ações, e seja $\beta_{ik}(t)$ a carga da ação i no fator k na data t.

A exposição agregada da carteira a cada fator principal k é dada por

$$E_k(t) = \sum_{i=1}^{N} w_i(t)\,\beta_{ik}(t), \qquad k = 1, \ldots, K. \tag{18}$$

Em notação vetorial, podemos escrever

$$E(t) = \big(E_1(t), \ldots, E_K(t)\big) = w(t)^\top B(t),$$

em que $B(t)$ é a matriz $N \times K$ de betas, ou seja, o vetor de exposições fatoriais é simplesmente o produto do vetor de pesos pelas colunas de betas.

O hedge multifatorial consiste em introduzir posições adicionais diretamente nos fatores de PCA (implementados como eigenportfólios) com o objetivo de cancelar essas exposições. Denotando por $h_k(t)$ o peso da carteira no k-ésimo fator principal, impomos que a exposição líquida após o hedge seja nula:

$$E_k^{\text{hedged}}(t) = E_k(t) + h_k(t) = 0, \qquad k = 1, \ldots, K.$$

Daqui, segue imediatamente que a escolha natural é

$$h_k(t) = -\,E_k(t) = -\sum_{i=1}^{N} w_i(t)\,\beta_{ik}(t), \qquad k = 1, \ldots, K. \tag{19}$$

Em forma compacta:

$$h(t) = -\,E(t) = -\,w(t)^\top B(t).$$

Na implementação numérica, o hedge é obtido calculando-se, para cada data, o vetor de exposições fatoriais $E(t)$ definido em (18), e atribuindo ao portfólio uma posição de igual magnitude e sinal oposto nos próprios fatores principais. Isso produz, ao longo do tempo, uma série de pesos alocados em cada fator de PCA, cuja única finalidade é cancelar as exposições sistemáticas induzidas pelas posições nas ações, sem alterar a estrutura relativa das posições geradas pelos sinais de reversão à média.

Uma vez aplicado o hedge, os pesos efetivos da estratégia podem ser decompostos em dois blocos:

- o bloco de ações, com pesos $w_i(t)$, construído a partir dos sinais de reversão à média e do esquema de pesos iguais por lado;
- o bloco de fatores, com pesos $h_k(t)$, cuja única função é cancelar as exposições sistemáticas $E_k(t)$.

O retorno da carteira passa a ser dado por

$$R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, R_i(t) + \sum_{k=1}^{K} h_k(t)\, R_k^F(t), \tag{20}$$

onde $R_k^F(t)$ é o retorno do k-ésimo fator principal (eigenportfólio) no intervalo $[t-1, t]$. Pela construção em (19), as parcelas associadas aos fatores sistemáticos se cancelam em primeira ordem, e o retorno resultante pode ser visto, em boa aproximação, como função apenas dos componentes idiossincráticos dos ativos.

5.6 Visão Geral da Estratégia

A estratégia proposta pode ser resumida em quatro etapas principais:

1. **Modelagem multifatorial e obtenção dos desvios idiossincráticos.** Os retornos das ações são decompostos em uma componente sistemática, explicada pelos fatores principais extraídos via PCA, e um componente residual $X_i(t)$, interpretado como desvio idiossincrático em relação ao nível implícito pelos fatores.

2. **Reversão à média e cálculo do s-score.** Cada processo residual $X_i(t)$ é modelado como Ornstein–Uhlenbeck, permitindo estimar seu ponto de equilíbrio e sua variabilidade estacionária. O s-score quantifica, em unidades padronizadas, o afastamento atual do ativo em relação ao equilíbrio, servindo como indicador de extremidade do desvio.

3. **Regras de entrada e saída baseadas em cortes.** Limiares pré-definidos sobre o s-score determinam a abertura de posições compradas ou vendidas, bem como seu encerramento, explorando exclusivamente episódios de desvios estatisticamente relevantes e sua posterior reversão à média.

4. **Construção do portfólio e neutralidade ao risco sistemático.** As posições selecionadas são convertidas em um portfólio long–short com pesos iguais por lado, garantindo neutralidade em valor. Em seguida, aplica-se um hedge multifatorial diretamente nos fatores de PCA, anulando exposições sistemáticas residuais e concentrando o desempenho da estratégia na componente idiossincrática.

Em conjunto, essas etapas definem uma metodologia de valor relativo orientada à reversão à média, cuja performance busca refletir exclusivamente a dinâmica idiossincrática dos ativos, minimizando a influência de movimentos amplos do mercado e de fatores comuns.

A composição final da carteira em cada data resulta da soma dos pesos alocados nas ações e dos pesos de hedge aplicados aos fatores principais. A figura a seguir ilustra a distribuição dos pesos efetivos do portfólio após todas as etapas da estratégia, evidenciando o caráter neutro e equilibrado da alocação resultante.

	MMM	AOS	ABT	ADBE	AMD	AES	AFL	APD	ALB	LNT	...	eig6	eig7	eig8
Date														
1998-01-02	0.010769	0.010769	0.0	0.000000	0.000000	0.0	0.0	0.000000	0.0	0.000000	...	-0.002345	0.011297	-0.000119
1998-01-05	0.008319	0.008319	0.0	0.000000	0.000000	0.0	0.0	-0.031007	0.0	0.008319	...	0.017273	0.032388	0.031560
1998-01-06	0.008005	0.008005	0.0	0.000000	-0.023014	0.0	0.0	-0.023014	0.0	0.008005	...	0.014030	0.033234	0.029559

Figura 1: Exemplo dos pesos finais do portfólio (ações + fatores de hedge)

Além disso, foi introduzido um parâmetro responsável por controlar a frequência de rebalanceamento da carteira. Esse parâmetro determina o intervalo temporal entre as atualizações dos pesos, permitindo que a estratégia mantenha a alocação corrente até a próxima data de rebalanceamento previamente estabelecida (por exemplo, a cada 30 dias). Dessa forma, evita-se o ajuste diário das posições.

6 Cálculo do PnL

Por fim, essa seção mostrará o cálculo do resultado financeiro da estratégia. Considere horizontes discretos $t = 0, 1, 2, \ldots$ correspondentes a dias de negociação. Denote por $R_i(t)$ o retorno (simples ou logarítmico, conforme con-

venção adotada) da ação i entre $t-1$ e t, e por $R_k^F(t)$ o retorno do fator k no mesmo intervalo.

Seja $w_i(t-1)$ o peso da ação i na carteira ao final do dia $t-1$, e $h_k(t-1)$ o peso de hedge no fator k. O retorno bruto da carteira no dia t é dado por

$$R_{\text{port}}^{\text{bruto}}(t) = \sum_{i=1}^{N} w_i(t-1)\, R_i(t) + \sum_{k=1}^{K_{\text{hedge}}} h_k(t-1)\, R_k^F(t). \tag{21}$$

Note que os pesos utilizados no cálculo do retorno do dia t são necessariamente aqueles vigentes ao final do dia $t-1$. Essa defasagem (*lag*) garante que a estratégia opere apenas com informações que estavam disponíveis no momento da decisão, evitando o chamado *look-ahead bias*. Em outras palavras, o retorno $R_{\text{port}}(t)$ é sempre calculado a partir dos pesos $w(t-1)$ e $h(t-1)$.

Para obter o PnL líquido, é necessário descontar os custos de transação associados ao rebalanceamento da carteira. Adota-se um custo proporcional fixo de $\epsilon = 5$ bps por unidade de capital movimentado, isto é, $\epsilon = 0{,}05$ custo por lado (abrir ou fechar).

Esse custo incide linearmente sobre a variação absoluta dos pesos entre $t-1$ e t, tanto no bloco de ações quanto no bloco de hedge. Assim, cada ajuste na carteira representa um custo proporcional ao montante de capital movimentado.

A variação absoluta de peso na ação i entre $t-1$ e t é $|\Delta w_i(t)| = |w_i(t) - w_i(t-1)|$, e definimos analogamente $|\Delta h_k(t)|$ para os pesos de hedge. O custo de transação total no dia t é então modelado como

$$C_{\text{tx}}(t) = \epsilon \left(\sum_{i=1}^{N} |\Delta w_i(t)| + \sum_{k=1}^{K_{\text{hedge}}} |\Delta h_k(t)| \right). \tag{22}$$

Além disso, a estratégia assume que 100% do patrimônio é alocado a cada dia. A distribuição do capital é inteiramente determinada pelos pesos vigentes no instante t.

O retorno líquido da estratégia no dia t é

$$R_{\text{port}}^{\text{líquido}}(t) = R_{\text{port}}^{\text{bruto}}(t) \; - \; C_{\text{tx}}(t). \tag{23}$$

A partir da série temporal de $R_{\text{port}}^{\text{líquido}}(t)$ é calculado o PnL acumulado e as estatísticas de desempenho usuais, tais como retorno anualizado, volatilidade,

índice de Sharpe e *max drawdown*. Essas medidas permitem avaliar em que medida a hipótese de reversão à média dos componentes idiossincráticos, capturada pelo modelo O–U e operacionalizada via s-scores, se traduz em ganhos econômicos após custos de transação e sob restrições de neutralidade sistemática.

7 Resultados do Backtest

Nesta seção são apresentados os resultados empíricos da estratégia de arbitragem estatística baseada em fatores principais. A análise é conduzida sob duas perspectivas temporais distintas: uma avaliação em horizonte mais curto, com foco em um período inicial da amostra, e uma avaliação em horizonte mais longo, contemplando toda a extensão dos dados disponíveis.

Incorporação do Termo de Drift

Foi investigado o impacto da inclusão de um termo de drift na modelagem do processo estocástico utilizado para estimar os escores de reversão à média.

Na formulação original sem drift, os resíduos idiossincráticos X_t são modelados por um processo de Ornstein–Uhlenbeck da forma:

$$dX_t = \kappa(m - X_t)\,dt + \sigma\,dW_t,$$

onde $\kappa > 0$ representa a velocidade de reversão à média, σ é o parâmetro de difusão e W_t é um movimento Browniano padrão. Nesse caso, a média de longo prazo do processo é zero, implicando que os desvios são avaliados em relação a uma referência fixa. Com a inclusão do termo de drift, a dinâmica passa a ser descrita por:

$$dX_t = \alpha dt + \kappa(m - X_t)\,dt + \sigma\,dW_t$$

onde μ representa a média de longo prazo estimada empiricamente. Nessa especificação, os desvios passam a ser medidos em relação a um nível médio não necessariamente nulo, permitindo acomodar possíveis deslocamentos estruturais no comportamento dos resíduos.

Com a inclusão do drift α_i, a dinâmica pode ser escrita como

$$dX_i(t) = \alpha_i\,dt + \kappa_i(m_i - X_i(t))\,dt + \sigma_i\,dW_t = \kappa_i\left(\frac{\alpha_i}{\kappa_i} + m_i - X_i(t)\right)dt + \sigma_i\,dW_t.$$

, ou seja,

$$dX_i(t) = \kappa_i \left(\frac{\alpha_i}{\kappa_i} - \sigma_{\mathrm{eq},i}\, s_i \right) dt = \kappa_i \sigma_{\mathrm{eq},i} \left(\frac{\alpha_i}{\kappa_i \sigma_{\mathrm{eq},i}} - s_i \right) dt$$

obtém-se que a variável de decisão natural passa a ser o *s-score modificado*:

$$s_{mod,i} = s_i - \frac{\alpha_i}{\kappa_i \sigma_{eq,i}} = s_i - \frac{\alpha_i \tau_i}{\sigma_{eq,i}},$$

onde $\tau_i = 1/\kappa_i$ representa o tempo característico de reversão à média.

Observa-se que o termo adicional desloca o s-score de acordo com o sinal e a magnitude do drift estimado. Em particular:

- se $\alpha_i > 0$ (tendência ascendente), o s-score modificado diminui;
- se $\alpha_i < 0$ (tendência descendente), o s-score modificado aumenta.

Do ponto de vista operacional, isso implica que:

- torna-se mais difícil gerar um sinal de venda (short) quando o resíduo apresenta drift positivo;
- torna-se mais fácil gerar um sinal de venda quando o resíduo apresenta drift negativo;
- mesmo quando $s_i = 0$, o sinal pode ser determinado exclusivamente pelo drift estimado.

Como o drift α_i pode ser interpretado empiricamente como a inclinação de uma média móvel (por exemplo, de 60 dias), a estratégia passa a incorporar implicitamente um componente de *momentum*. Assim, além do mecanismo de reversão à média, surge um efeito direcional embutido no critério de decisão.

7.1 Análise de Curto Prazo

Inicialmente, considera-se um horizonte mais curto, compreendendo o período de 2000 a 2007 para o mercado brasileiro e de 1997 a 2007 para o mercado norte-americano. O objetivo dessa etapa é analisar o comportamento da estratégia em uma janela temporal mais homogênea, permitindo uma avaliação mais controlada do impacto das escolhas paramétricas.

Parâmetros Fixos e Número de Fatores Constante

A primeira análise é conduzida com parâmetros fixos e simétricos para os limiares de abertura e fechamento das posições, de forma parecida à abordagem utilizada em (AVELLANEDA; LEE, 2008):

$$s_{bo} = 1{,}25, \quad s_{so} = 1{,}25, \quad s_{bc} = 0{,}50, \quad s_{sc} = 0{,}50.$$

Para o mercado brasileiro, utiliza-se $num_pc = 3$, enquanto para o mercado norte-americano adota-se $num_pc = 10$, refletindo a maior dimensão e diversificação do universo de ativos dos Estados Unidos. Para cada mercado são apresentados resultados considerando duas especificações do modelo:

- estratégia sem correção de drift;
- estratégia com correção de drift.

Essa comparação permite avaliar o impacto da inclusão do termo de drift na modelagem do processo de Ornstein–Uhlenbeck utilizado para estimar os escores de reversão à média.

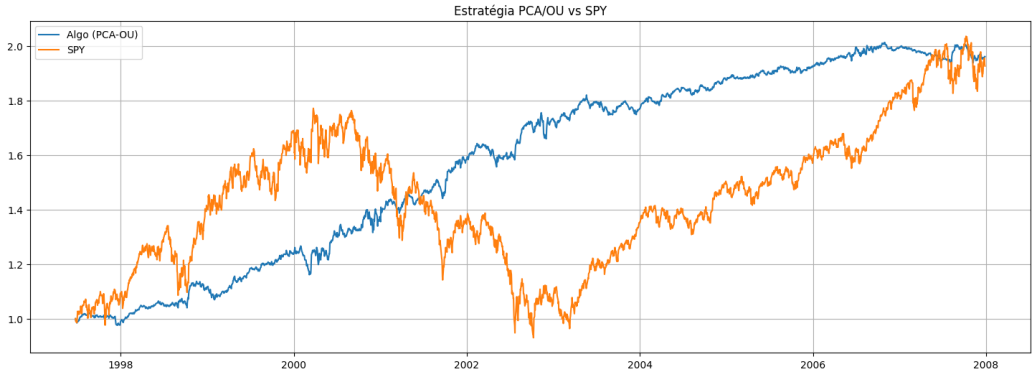

(a) Sem drift — Sharpe = 1.0909, CAGR = 0.0633

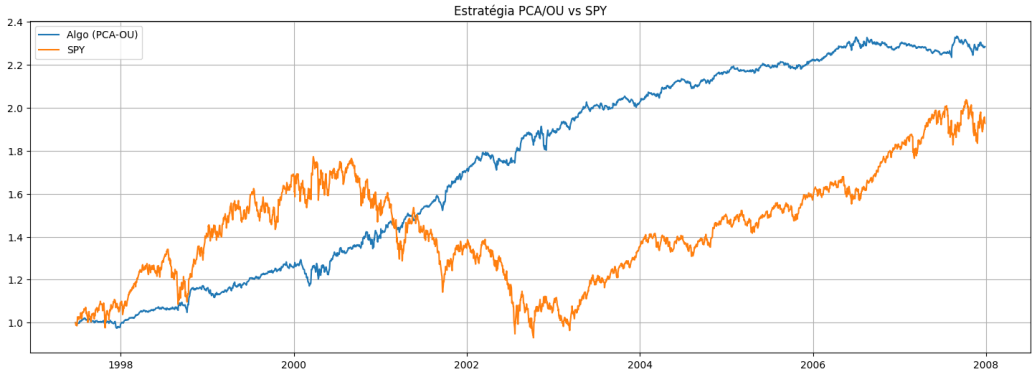

(b) Com drift — Sharpe = 1.3562, CAGR = 0.0784

Figura 2: Desempenho da estratégia no mercado norte-americano com parâmetros fixos.

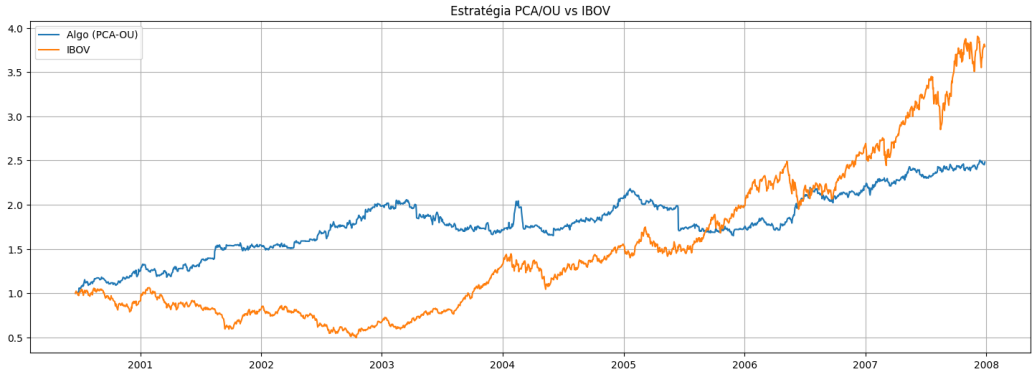

(a) Sem drift — Sharpe = 0.8123, CAGR = 0.1179

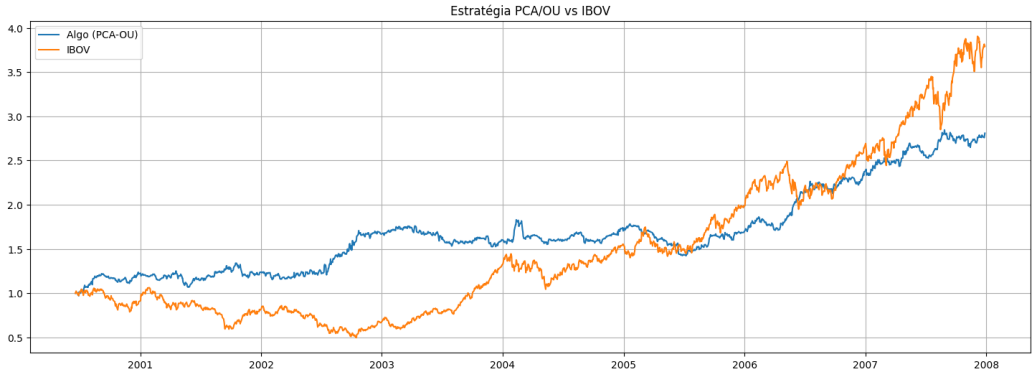

(b) Com drift — Sharpe = 0.9017 , CAGR = 0.1349

Figura 3: Desempenho da estratégia no mercado brasileiro com parâmetros fixos.

Número de Componentes Principais Adaptativo

Em seguida, analisa-se uma versão da estratégia na qual o número de componentes principais não é fixado *a priori*, mas determinado de forma adaptativa com base na variância explicada acumulada.

Inicialmente, considera-se um alvo de 70% da variância total do sistema, de modo que o número de fatores utilizados em cada janela passa a depender da estrutura contemporânea de covariância dos retornos.

Posteriormente, apresenta-se uma análise de sensibilidade na qual o alvo de variância explicada varia de 50% a 90%. Essa análise permite investigar como o desempenho da estratégia reage a diferentes níveis de compressão

dimensional via PCA.

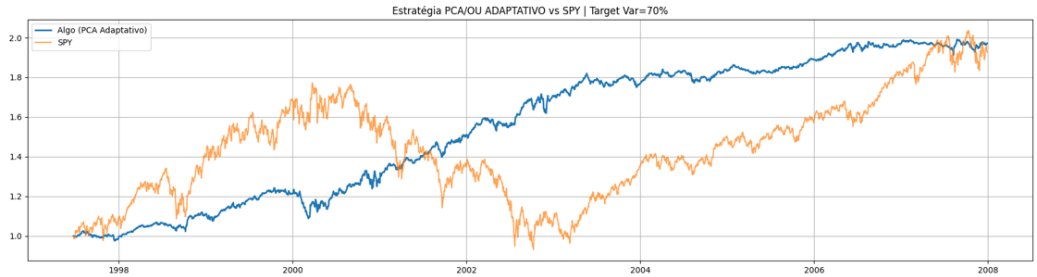

(a) Desempenho da estratégia com número de componentes principais determinado adaptativamente para explicar 70% da variância total. Sharpe = 1.3047, CAGR = 0.0798

(b) Número de componentes principais selecionados ao longo do tempo para atingir o alvo de 70% de variância explicada.

Figura 4: Desempenho da estratégia no mercado americando com PC adaptativos.

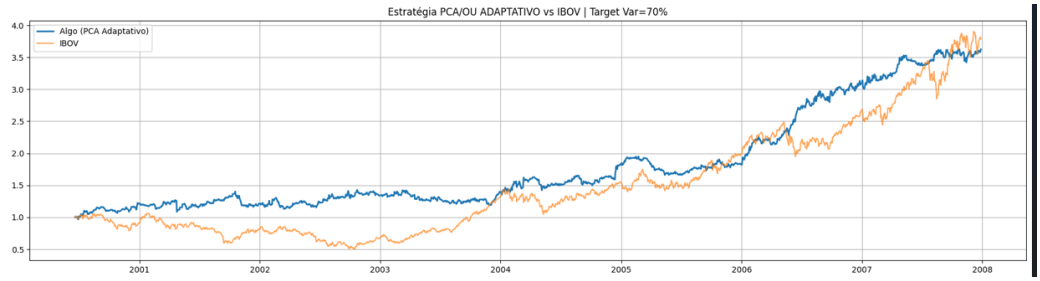

(a) Desempenho da estratégia com número de componentes principais determinado adaptativamente para explicar 70% da variância total. Sharpe = 0.9446, CAGR = 0.1710

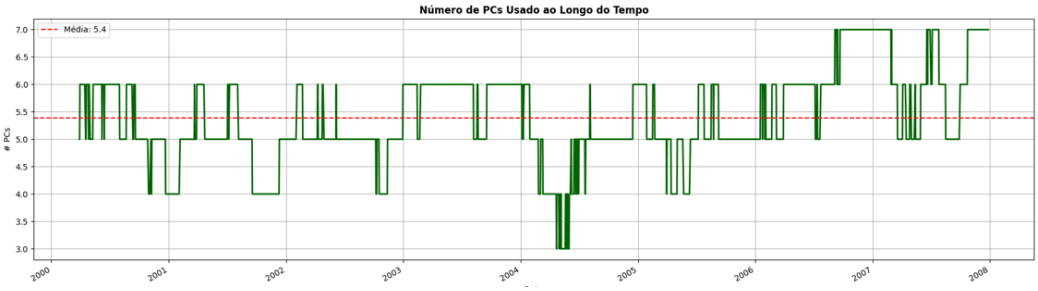

(b) Número de componentes principais selecionados ao longo do tempo para atingir o alvo de 70% de variância explicada.

Figura 5: Desempenho da estratégia no mercado brasileiro com PC adaptativos.

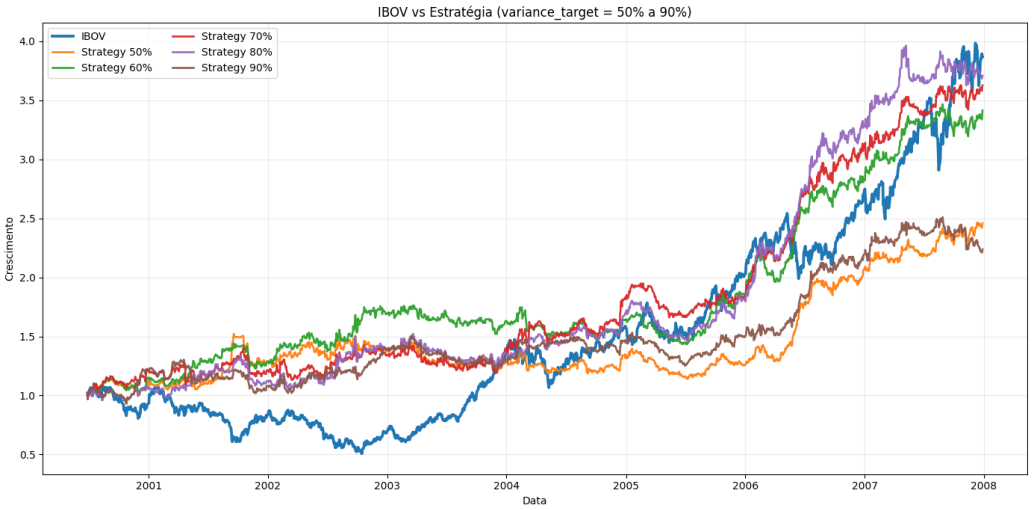

Figura 6: Análise de sensibilidade do desempenho da estratégia para diferentes níveis de variância explicada acumulada (50%–90%).

Limiar Adaptativo via Quantis

Por fim, avalia-se uma versão da estratégia em que os limiares de abertura e fechamento das posições não são fixos, mas determinados dinamicamente com base em quantis empíricos da distribuição histórica dos escores (s-scores).

Nesse caso, os thresholds passam a refletir a dispersão observada no período recente, tornando o critério de entrada e saída dependente do regime de volatilidade vigente. Essa abordagem permite comparar diretamente regras paramétricas fixas com regras adaptativas baseadas na própria distribuição dos sinais.

Mais precisamente, para cada ação i, os níveis de entrada e saída são determinados com base nos percentis da série temporal s_i, t, permitindo que os sinais sejam normalizados em relação à sua própria dinâmica.

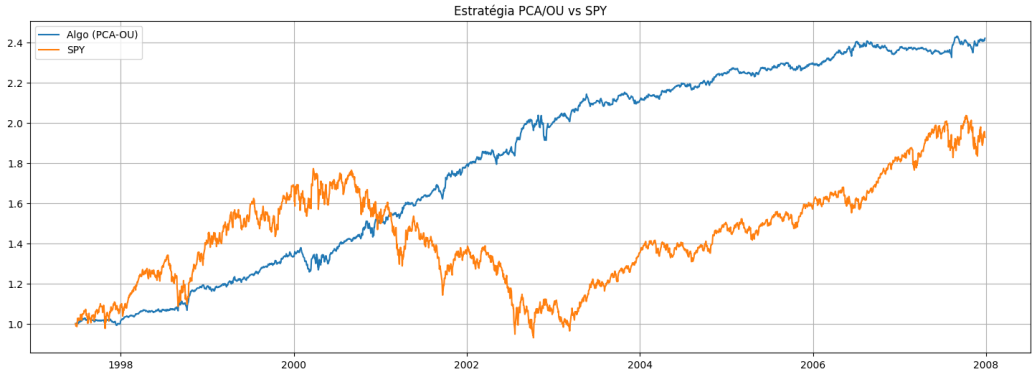

Figura 7: Desempenho da estratégia no mercado americano com limiares adaptativos baseados em quantis da distribuição recente dos s-scores. Sharpe = 1.4913, CAGR 0.0840

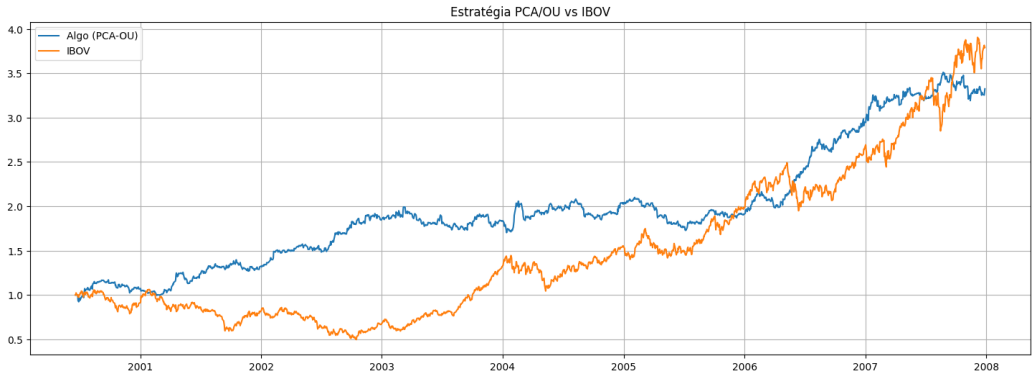

Figura 8: Desempenho da estratégia no mercado brasileiro com limiares adaptativos baseados em quantis da distribuição recente dos s-scores. Sharpe = 1.0526, CAGR 0.1586

Interpretação operacional. Na implementação considerada, os limiares de abertura são definidos a partir dos quantis extremos da distribuição recente dos s-scores. Em particular, posições compradas são abertas quando o s-score entra aproximadamente nos 10% menores valores observados na janela histórica, enquanto posições vendidas são iniciadas quando o s-score atinge os 10% maiores valores. Os critérios de fechamento são mais centrais: posições vendidas são encerradas quando o s-score retorna para abaixo de

aproximadamente 55% da distribuição, enquanto posições compradas são fechadas quando o processo reverte para valores próximos à mediana. Dessa forma, a estratégia busca explorar desvios extremos da média e realizar lucros quando ocorre uma reversão parcial em direção ao centro da distribuição.

Estratégia Combinada: Componentes e Limiar Adaptativos

Após analisar separadamente as extensões com número adaptativo de componentes principais e com limiares de negociação definidos por quantis, considera-se agora a versão combinada da estratégia.

Nessa configuração, o número de componentes principais utilizados na decomposição é determinado dinamicamente a partir da variância explicada acumulada, permitindo que a representação fatorial se ajuste às mudanças na estrutura de correlação do mercado.

Simultaneamente, os limiares de abertura e fechamento das posições são definidos de forma adaptativa com base em quantis empíricos da distribuição histórica dos s-scores, tornando o critério de negociação sensível ao regime recente de dispersão dos resíduos.

A combinação desses dois mecanismos busca tornar a estratégia mais robusta a mudanças nas condições de mercado, adaptando tanto a identificação dos fatores quanto as regras de geração de sinais.

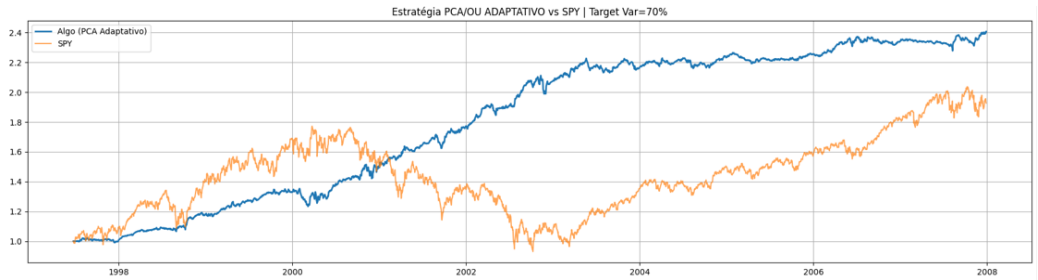

Figura 9: Desempenho da estratégia no mercado americano com número de componentes principais determinado adaptativamente para explicar 70% da variância total combinados com quantis da distribuição do s-scores. Sharpe = 1.4628, CAGR = 0.0835

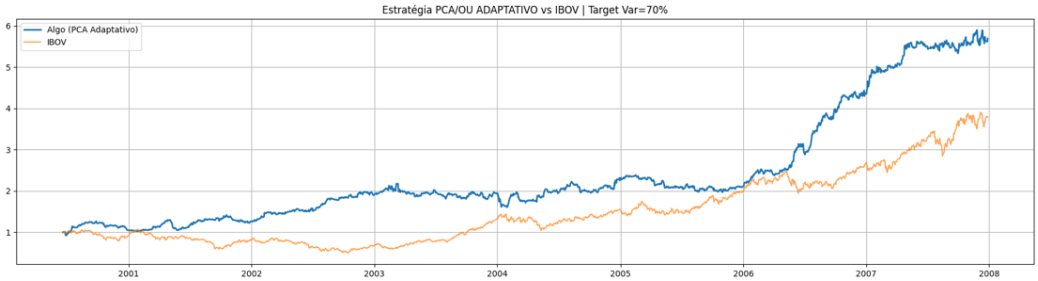

Figura 10: Desempenho da estratégia no mercado brasileiro com número de componentes principais determinado adaptativamente para explicar 70% da variância total combinados com quantis da distribuição do s-scores. Sharpe = 1.2585, CAGR = 0.2377

7.2 Análise de Longo Prazo

Na sequência, repete-se a análise considerando o horizonte completo da amostra: 2000–2025 para o mercado brasileiro e 1997–2025 para o mercado norte-americano.

Nesta etapa, o foco recai principalmente sobre a robustez da estratégia ao longo de diferentes regimes econômicos e ciclos de mercado. Para evitar redundância, são apresentados diretamente os principais gráficos de desempenho acumulado, bem como métricas sintéticas de risco e retorno, destacando-se as diferenças estruturais observadas entre as especificações com parâmetros fixos, número de fatores adaptativo e limiares baseados em quantis.

Essa organização permite comparar, de forma sistemática, a estabilidade da estratégia em horizontes distintos e avaliar a consistência dos resultados sob diferentes estruturas paramétricas.

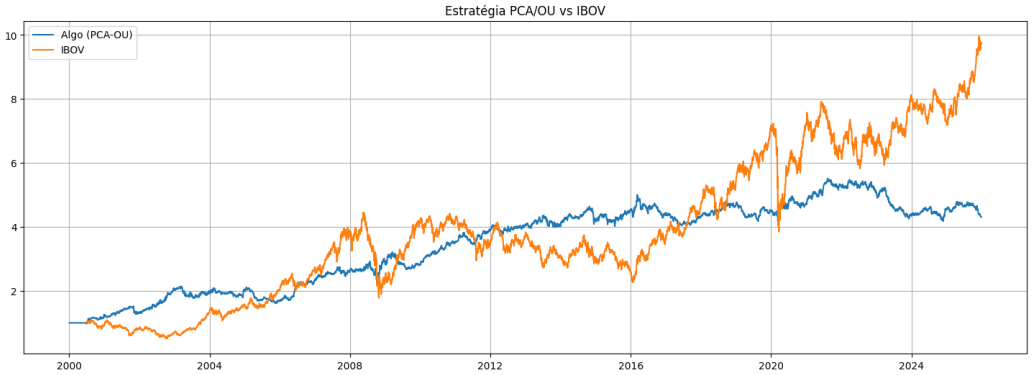

(a) Com drift — Sharpe = 0.4742, CAGR = 0.0581

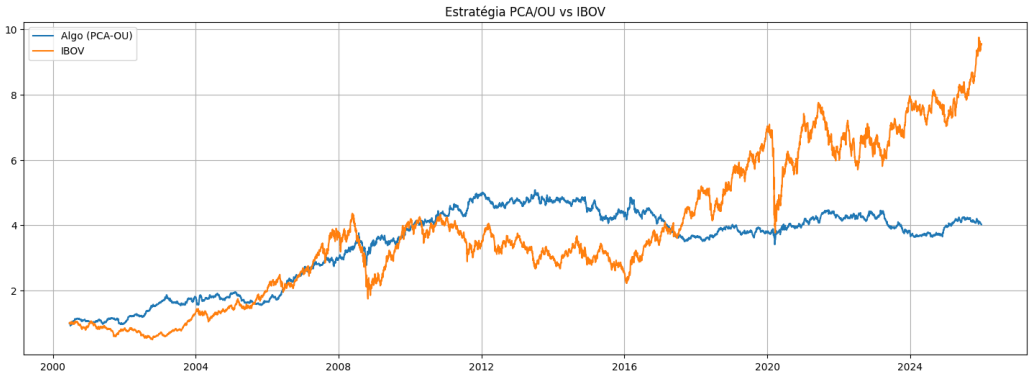

(b) Thresholds via quantis — Sharpe = 0.4400, CAGR = 0.0552

Figura 11: Desempenho da estratégia no mercado brasileiro com thresholds fixos e adaptados por quantis.

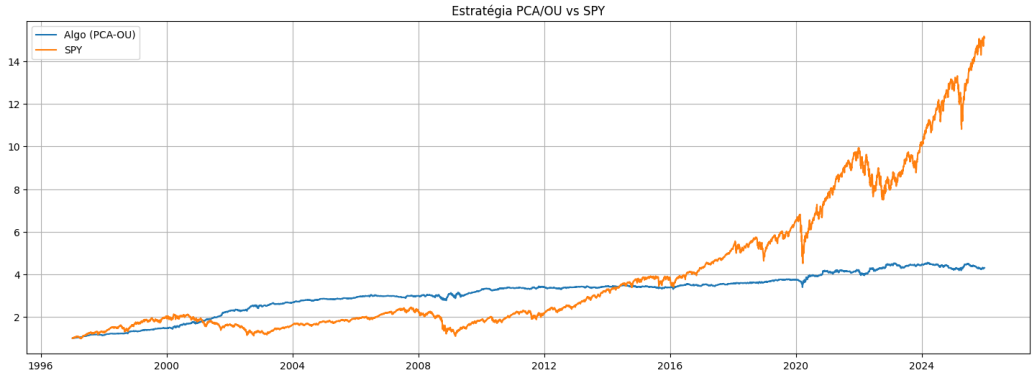

(a) Com drift — Sharpe = 1.0436, CAGR = 0.0560

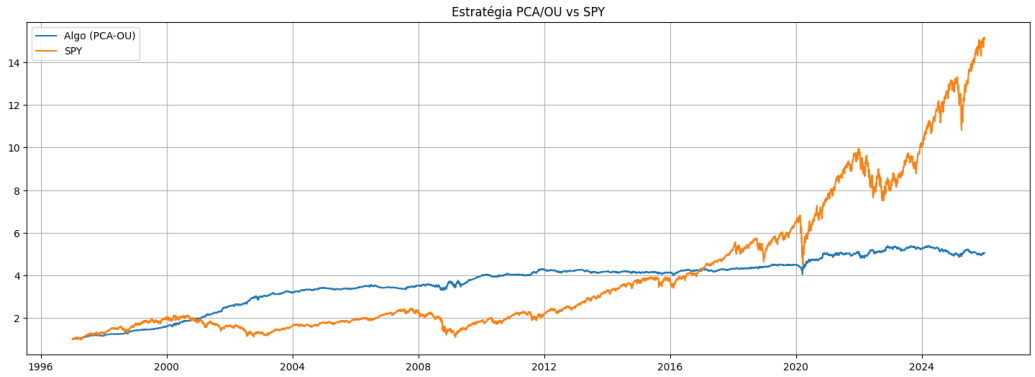

(b) Thresholds via quantis — Sharpe = 1.1778, CAGR = 0.0626

Figura 12: Desempenho da estratégia no mercado americano com thresholds fixos e adaptados por quantis.

Por fim, avalia-se a versão combinada da estratégia, aquela que apresentou o melhor desempenho na análise de curto prazo, na qual se utiliza simultaneamente limiares adaptativos baseados em quantis e um número de componentes principais definido de forma dinâmica ao longo do tempo.

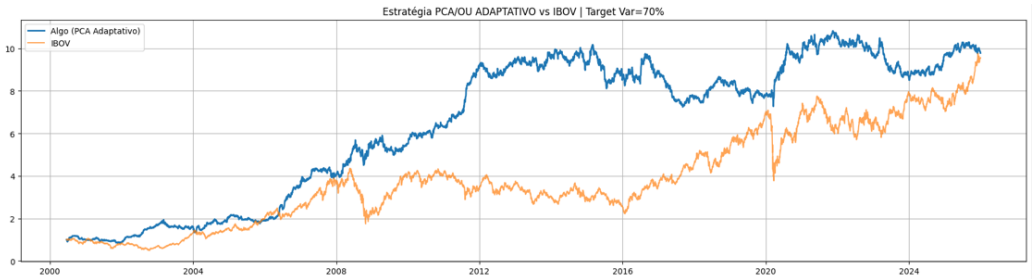

Figura 13: Desempenho da estratégia com thresholds via quantis e PCA adaptativo no mercado brasileiro. Sharpe = 0.6186, CAGR = 0.0920

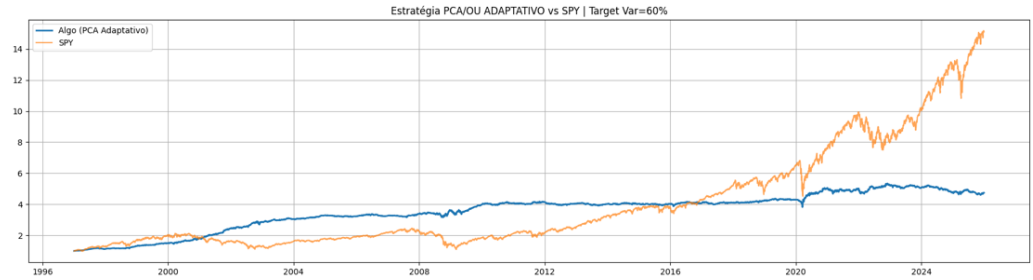

Figura 14: Desempenho da estratégia com thresholds via quantis e PCA adaptativo no mercado americano. Sharpe = 1.0431, CAGR = 0.0603

7.3 Otimização no Horizonte de Longo Prazo

Embora a estratégia tenha apresentado desempenho consistente no mercado brasileiro, os resultados obtidos para o mercado norte-americano evidenciam uma deterioração relevante ao longo do horizonte completo da amostra. Esse comportamento sugere que a parametrização adotada pode não ser estável ao longo do tempo, especialmente em ambientes caracterizados por mudanças estruturais nas dinâmicas de mercado.

Diante disso, torna-se natural investigar se ajustes sistemáticos nos hiperparâmetros são capazes de restaurar o poder preditivo da metodologia. Em particular, busca-se avaliar se a escolha adequada de parâmetros pode mitigar a perda de desempenho observada fora da amostra.

Com esse objetivo, são considerados dois esquemas distintos de otimização de hiperparâmetros, ambos baseados no algoritmo *Tree-structured Parzen Estimator* (TPE), conforme implementado na biblioteca `Optuna`. Esses es-

quemas diferem essencialmente na forma como a calibração é conduzida ao longo do tempo, permitindo analisar o papel da estabilidade versus adaptabilidade na performance da estratégia.

Primeiro Estudo: Parametrização Fixa Calibrada no Período Inicial

Como primeiro passo, busca-se avaliar se existe uma combinação de hiperparâmetros capaz de apresentar desempenho robusto quando calibrada em um período inicial da amostra e posteriormente mantida constante ao longo do tempo.

Esse experimento simula uma situação prática em que o investidor realiza um processo de calibração utilizando dados históricos e, a partir disso, implementa a estratégia de forma estática, sem ajustes adicionais. Trata-se, portanto, de um teste direto de estabilidade temporal da parametrização.

Para a etapa de calibração, foi considerado o período de 1997 a 2002 no mercado norte-americano. A fim de reduzir o risco de sobreajuste a um único intervalo específico, adotou-se um esquema de validação temporal com múltiplas janelas sobrepostas, capturando diferentes condições de mercado dentro do período de treinamento.

As janelas utilizadas foram:

- 1997–1999,
- 1998–2000,
- 1999–2001,
- 2000–2002.

Para cada combinação de hiperparâmetros, a estratégia foi avaliada separadamente em cada uma dessas janelas. O critério de seleção adotado foi o índice de Sharpe médio entre os quatro períodos, permitindo identificar configurações que apresentem desempenho consistente, e não apenas resultados favoráveis em intervalos específicos.

O processo de busca foi conduzido por meio do algoritmo *Tree-structured Parzen Estimator* (TPE), implementado na biblioteca `Optuna`, sendo avaliadas 80 combinações distintas de parâmetros.

A Figura 15 apresenta o desempenho acumulado da estratégia no período de treinamento utilizando a combinação de parâmetros selecionada, ilustrando o comportamento in-sample ao longo das diferentes janelas consideradas.

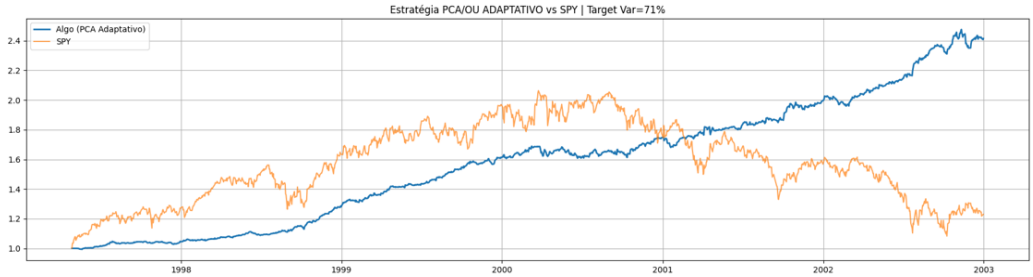

Figura 15: Desempenho acumulado da estratégia no período de treinamento utilizando a melhor combinação de parâmetros selecionada pelo processo de otimização.

Uma vez determinada a parametrização ótima, esta foi mantida fixa e aplicada ao restante da amostra, no período de 2005 a 2025, caracterizando um experimento genuinamente fora da amostra (*out-of-sample*).

Esse procedimento permite avaliar diretamente se uma parametrização calibrada em um período inicial é capaz de se manter eficiente ao longo do tempo, ou se seu desempenho depende fortemente das condições específicas do período de calibração.

Os resultados fora da amostra são apresentados na Figura 16.

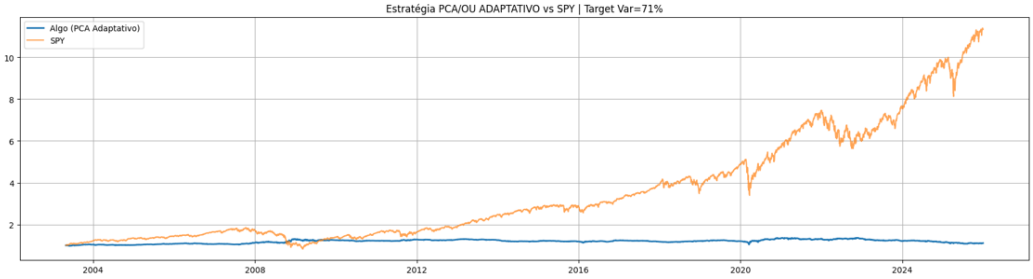

Figura 16: Desempenho fora da amostra da estratégia utilizando parâmetros calibrados no período inicial.

Segundo Estudo: Otimização Recorrente com Recalibração Periódica

No segundo estudo, buscou-se incorporar maior adaptabilidade ao processo de calibração, reconhecendo que os padrões estatísticos do mercado podem se modificar ao longo do tempo. Em vez de manter uma única parametrização fixa durante todo o horizonte de investimento, os hiperparâmetros da estratégia passaram a ser reestimados periodicamente, utilizando apenas informações disponíveis até o instante da decisão.

Diferentemente do primeiro estudo, em que a seleção era realizada em uma etapa única e inicial, aqui foi adotado um procedimento de recalibração recorrente no estilo *walk-forward*. A ideia é reproduzir um cenário mais próximo da prática, no qual a estratégia é reotimizada ao longo do tempo e aplicada prospectivamente aos períodos seguintes.

Neste estudo, considerou-se novamente apenas o mercado norte-americano. O procedimento implementado foi o seguinte:

- para cada ano de teste, utilizam-se os dois anos imediatamente anteriores como janela de treinamento;
- essa janela de treinamento é dividida em dois blocos anuais, correspondentes a cada um dos dois anos anteriores;
- em cada etapa de otimização, são avaliadas 60 combinações de hiperparâmetros;
- para cada combinação, a estratégia é executada separadamente em cada bloco anual de treino;
- o critério de seleção consiste na maximização da média do índice de Sharpe obtido nesses dois blocos;
- os parâmetros selecionados são então aplicados fora da amostra no período de teste subsequente.

Além disso, a reotimização não é realizada todos os anos, mas sim a cada dois anos. Dessa forma, uma vez obtida uma nova combinação de parâmetros, ela é mantida até a próxima etapa de recalibração. O código também utiliza, em cada nova etapa de otimização, o melhor conjunto de parâmetros anterior como ponto inicial (*warm start*), tornando o processo mais estável e computacionalmente mais eficiente.

Assim, o experimento avalia se uma estratégia com recalibração periódica baseada apenas nos dois anos mais recentes é capaz de produzir desempenho mais robusto ao longo do tempo do que uma parametrização fixa obtida em um único período inicial.

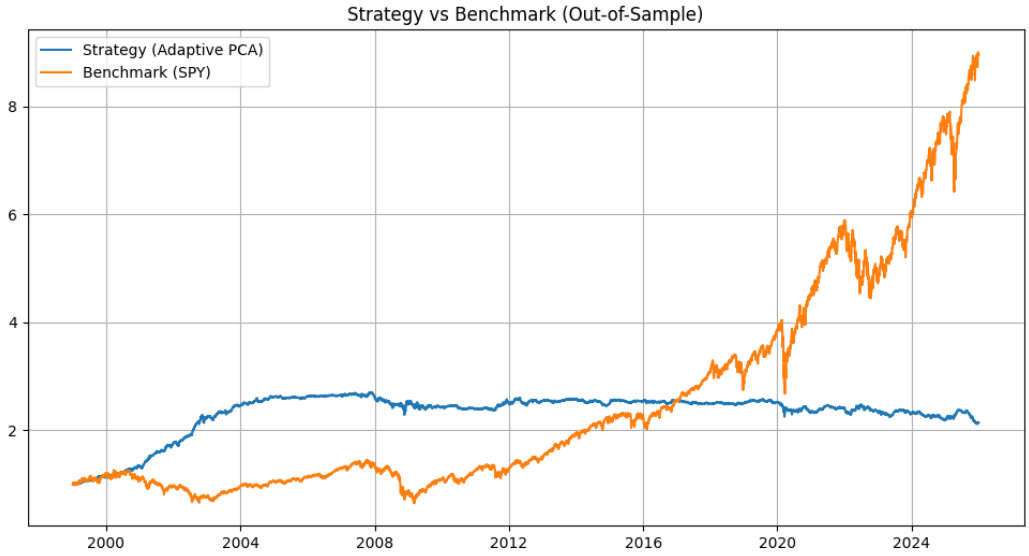

Figura 17: Desempenho acumulado da estratégia no mercado norte-americano sob o procedimento de otimização recorrente com recalibração periódica. Em cada etapa, os parâmetros são selecionados com base nos dois anos anteriores, sendo o critério de escolha a média do índice de Sharpe obtido em dois blocos anuais de treinamento. Sharpe = 0.5093, CAGR = 0.0292.

Para melhor compreender a dinâmica desse processo, o Apêndice C apresenta a evolução temporal dos principais parâmetros selecionados ao longo das sucessivas reotimizações. Essa análise evidencia que a calibração ótima da estratégia varia de forma significativa ao longo do tempo, refletindo mudanças nos regimes de mercado tanto na estrutura fatorial quanto na intensidade dos sinais de reversão e na frequência operacional da carteira.

Em conjunto, esses resultados sugerem que, embora a reotimização recorrente permita maior adaptabilidade, a simples atualização periódica dos hiperparâmetros pode não ser suficiente para garantir robustez fora da amostra, especialmente em mercados mais eficientes e competitivos, como o norte-americano.

8 Melhorias sugeridas

Apesar da estratégia apresentar resultados consistentes em determinados períodos e configurações, em especial no mercado brasileiro, os experimentos conduzidos ao longo deste trabalho evidenciam limitações importantes, especialmente no que diz respeito à estabilidade temporal no mercado americano. Em particular, observa-se que os procedimentos de otimização implementados não foram capazes de produzir ganhos sistemáticos de desempenho no longo prazo.

Diante disso, esta seção discute possíveis extensões metodológicas que podem ser investigadas em trabalhos futuros, com o objetivo de tornar a estratégia mais robusta, adaptativa e alinhada às características de curto prazo típicas da arbitragem estatística.

Gestão de risco e alocação de capital

Na implementação atual, a estratégia assume implicitamente a alocação integral do capital disponível nas posições abertas, distribuído uniformemente entre os ativos selecionados. Embora essa abordagem simplifique a construção do portfólio, ela pode levar a níveis elevados de exposição agregada e não incorpora mecanismos explícitos de controle de risco.

Uma extensão natural consiste em incorporar restrições adicionais, como limites máximos de exposição por ativo, controle de alavancagem total ou regras de redução de risco em períodos de alta volatilidade. Essas modificações tornam a estratégia mais compatível com práticas reais de gestão de portfólio e podem contribuir para melhorar sua relação risco-retorno.

Pesos proporcionais ao sinal de reversão

A estratégia atual utiliza um esquema de pesos iguais por lado, no qual todos os ativos selecionados recebem a mesma alocação dentro dos blocos *long* e *short*. Embora essa escolha favoreça diversificação e simplicidade, ela ignora a intensidade relativa dos sinais gerados pelo modelo.

Uma alternativa promissora consiste em ponderar os pesos das posições pela magnitude do s-score. Nesse caso, ativos com desvios mais extremos em relação ao equilíbrio receberiam maior alocação de capital, refletindo maior convicção no sinal de reversão à média.

Essa abordagem permite explorar de forma mais eficiente a informação contida no indicador, potencialmente aumentando o retorno esperado da estratégia. No entanto, tal modificação exige cuidado adicional no controle de risco, pois pode introduzir concentração excessiva em poucos ativos com sinais extremos.

Horizonte de calibração e estrutura de treinamento

Uma vez que os sinais de reversão são baseados em desvios idiossincráticos transitórios e o rebalanceamento ocorre em frequências relativamente elevadas, a utilização de janelas de calibração e treinamento longas pode não ser a escolha mais adequada, pois tende a incorporar informações históricas que já não refletem as condições atuais de mercado nesse curto prazo de movimentação.

Na implementação considerada, os processos de estimação dos parâmetros e de otimização foram conduzidos com janelas relativamente extensas (tipicamente da ordem de anos), com o objetivo de garantir maior estabilidade estatística. No entanto, os resultados fora da amostra indicam que essa abordagem não foi capaz de produzir ganhos consistentes, sugerindo possível desalinhamento entre o horizonte de calibração e o horizonte efetivo de atuação da estratégia.

Diante disso, uma extensão natural consiste em investigar o uso de janelas significativamente mais curtas, tanto na estimação dos parâmetros do processo O–U quanto na definição dos limiares de decisão e nos procedimentos de otimização. Em particular, pode-se considerar períodos de treinamento de poucos meses, ou até mesmo abordagens com atualização contínua baseada apenas em dados recentes.

A motivação para essa modificação reside no fato de que janelas mais curtas podem permitir que a estratégia capture com maior rapidez mudanças no regime de mercado, tornando-a mais responsiva a dinâmicas contemporâneas. Essa característica pode ser especialmente relevante em ambientes instáveis, nos quais relações históricas se deterioram rapidamente.

Entretanto, essa hipótese não foi explorada empiricamente neste trabalho e permanece como uma direção aberta de investigação.

Inclusão de ativos com baixa velocidade de reversão

Na implementação atual, ativos com velocidade de reversão à média abaixo de um determinado limiar são excluídos da estratégia, com o objetivo de evitar a inclusão de séries com dinâmica pouco previsível.

No entanto, essa filtragem pode eliminar ativos que, embora apresentem reversão mais lenta, ainda contenham informação útil para a estratégia. Além disso, a imposição desse critério reduz o universo de investimento e pode limitar a diversificação do portfólio.

Uma extensão interessante consiste em remover esse filtro e avaliar o desempenho da estratégia quando aplicada ao conjunto completo de ativos. Alternativamente, pode-se adotar uma abordagem mais flexível, na qual ativos com diferentes velocidades de reversão recebem pesos diferenciados, em vez de serem simplesmente excluídos.

Essa análise permite verificar se a estratégia é capaz de extrair valor mesmo em regimes de reversão mais lenta, ou se o filtro atual é de fato essencial para sua eficácia.

Em conjunto, essas extensões apontam para um caminho de evolução da estratégia em direção a maior adaptabilidade, melhor controle de risco e uso mais eficiente da informação contida nos sinais de reversão. A investigação sistemática dessas melhorias constitui uma agenda natural para trabalhos futuros.

9 Conclusão

Esta dissertação teve como objetivo desenvolver, implementar e avaliar empiricamente uma estratégia de arbitragem estatística neutra ao mercado baseada em fatores extraídos por Análise de Componentes Principais (PCA) e modelagem de reversão à média por meio de processos de Ornstein–Uhlenbeck.

A metodologia proposta combina três elementos centrais da literatura de *statistical arbitrage*: (i) a decomposição dos retornos em componentes sistemáticos e idiossincráticos via PCA; (ii) a modelagem dos resíduos como processos de reversão à média; e (iii) a construção de portfólios long–short com neutralização explícita das exposições fatoriais. Essa integração permitiu construir uma estratégia consistente do ponto de vista estatístico e alinhada com práticas modernas de investimento quantitativo.

Os resultados empíricos indicam que a estratégia apresenta desempenho relevante, porém fortemente dependente do mercado considerado. No mercado brasileiro, observou-se desempenho consistente tanto no curto quanto no longo prazo, com indicadores de retorno ajustado ao risco satisfatórios mesmo após a consideração de custos de transação. Esse resultado sugere que a estrutura de reversão à média dos componentes idiossincráticos é mais persistente nesse ambiente, possibilitando a extração de ganhos de forma mais estável.

Por outro lado, no mercado norte-americano, embora a estratégia tenha apresentado resultados expressivos no curto prazo, sua performance deteriora-se de forma significativa ao longo do horizonte completo da amostra. Essa evidência sugere que a hipótese de reversão à média dos resíduos fatoriais pode ser menos robusta em mercados mais eficientes e competitivos, nos quais as ineficiências são rapidamente arbitradas.

Além disso, os experimentos de otimização de hiperparâmetros mostraram que tanto abordagens com parametrização fixa quanto esquemas de recalibração recorrente não foram capazes de restaurar de forma consistente o desempenho fora da amostra no longo prazo. Esse resultado reforça a hipótese de que a limitação da estratégia não reside apenas na escolha de parâmetros, mas possivelmente em mudanças estruturais nas dinâmicas de mercado e na própria natureza dos sinais explorados.

Em conjunto, os resultados obtidos evidenciam que estratégias de arbitragem estatística baseadas em reversão à média apresentam sensibilidade relevante ao contexto de mercado e ao horizonte de análise. Embora a abordagem proposta se mostre eficaz em determinados cenários, especialmente

em mercados com menor eficiência relativa, sua robustez em ambientes mais competitivos exige adaptações adicionais.

Por fim, as extensões discutidas ao longo do trabalho, incluindo melhorias na gestão de risco, uso de pesos proporcionais aos sinais, e principalmente a revisão do horizonte de calibração, apontam caminhos promissores para o aprimoramento da estratégia. A investigação sistemática dessas direções constitui uma agenda natural para pesquisas futuras, podendo contribuir para o desenvolvimento de modelos mais adaptativos e robustos em estratégias de arbitragem estatística.

Reprodutibilidade Os códigos utilizados para implementação da estratégia, execução dos backtests e geração dos resultados apresentados neste trabalho estão disponíveis publicamente em:

⟨https://github.com/savio160502/Statistical-Arbitrage⟩

O repositório inclui scripts de processamento de dados, construção dos fatores de PCA, estimação do modelo de Ornstein–Uhlenbeck, bem como os procedimentos de otimização e avaliação empírica da estratégia.

10 Referências

Referências

ANDERSEN, M. S. An introductory note on the environmental economics of the circular economy. *Sustainability Science*, v. 2, n. 1, p. 133–140, 2007. ISSN 1862-4057. Disponível em: ⟨https://doi.org/10.1007/s11625-006-0013-6⟩.

AVELLANEDA, M.; LEE, J.-H. Statistical arbitrage in the u.s. equities market. *SSRN Electronic Journal*, 2008. Disponível em: ⟨https://ssrn.com/abstract=1153505⟩.

BERTRAM, W. Analytic solutions for optimal statistical arbitrage trading. *Physica A: Statistical Mechanics and its Applications*, v. 389, n. 11, p. 2234–2243, 2010.

ELLIOTT, R. J.; HOEK, J. V. D.; MALCOLM, W. P. Pairs trading. *Quantitative Finance*, v. 5, n. 3, p. 271–276, 2005.

GATEV, E.; GOETZMANN, W. N.; ROUWENHORST, K. G. Pairs trading: Performance of a relative-value arbitrage rule. *Review of Financial Studies*, v. 19, n. 3, p. 797–827, 2006.

GÖNCÜ, A.; AKYILDIRIM, E. Statistical arbitrage with pairs trading. *International Review of Finance*, v. 16, n. 2, p. 307–319, 2016.

GUIJARRO-ORDONEZ, J.; PELGER, M.; ZANOTTI, G. Deep learning statistical arbitrage. *Working Paper*, 2022. First draft: 2019. This draft: 2022. Disponível em: ⟨https://papers.ssrn.com/sol3/papers.cfm?abstract_id=xxxxxxx⟩.

HOGAN, S. et al. Testing market efficiency using statistical arbitrage with applications to momentum and value strategies. *Journal of Financial Economics*, v. 73, n. 3, p. 525–565, 2004.

KUMAR, N. *Advantages and Disadvantages of Principal Component Analysis in Machine Learning*. 2019. ⟨http://theprofessionalspoint.blogspot.com/2019/03/advantages-anddisadvantages-of_4.html⟩. Accessed: 2021-04-15.

STANKOVIć, J. J. et al. An integrated approach of pca and promethee in spatial assessment of circular economy indicators. *Waste Management*, v. 128, p. 154–166, 2021. ISSN 0956-053X. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S0956053X21002555⟩.

TABACHNICK, B. G.; FIDELL, L. S. *Using Multivariate Statistics*. 6. ed. New York: Harper and Row, 2012. ISBN 9780205849574.

VIDYAMURTHY, G. *Pairs Trading: Quantitative Methods and Analysis*. Hoboken: Wiley, 2004.

WANG, J. et al. A novel combination of pca and machine learning techniques to select the most important factors for predicting tunnel construction performance. *Buildings*, v. 12, n. 7, 2022. ISSN 2075-5309. Disponível em: ⟨https://www.mdpi.com/2075-5309/12/7/919⟩.

ZENG, Y.; LEE, B. S. Pushing the limit of pairs trading strategies. *Quantitative Finance*, v. 14, n. 10, p. 1783–1795, 2014.

11 Apêndices

A Processo de Ornstein–Uhlenbeck: cálculo e estimação dos parâmetros

Neste apêndice descrevemos, em maior detalhe, o procedimento utilizado para calibrar o processo de Ornstein–Uhlenbeck (O–U) que modela os desvios idiossincráticos $X_i(t)$ e para calcular os respectivos s-scores. Seguindo Avellaneda e Lee (AVELLANEDA; LEE, 2008), introduzimos um modelo paramétrico para o processo de desvios idiossincráticos $X_i(t)$, baseado no processo de Ornstein–Uhlenbeck (O–U):

$$dX_i(t) = \kappa_i\big(m_i - X_i(t)\big)\,dt + \sigma_i\,dW_i(t), \qquad \kappa_i > 0, \tag{24}$$

em que:

- m_i é o nível de equilíbrio de longo prazo do desvio idiossincrático;
- κ_i é a velocidade de reversão à média;
- σ_i é a intensidade dos choques idiossincráticos;
- $W_i(t)$ é um movimento browniano padrão.

Esse processo é gaussiano, markoviano e estacionário (para $\kappa_i > 0$), e sua versão em tempo discreto, amostrada em passos Δt, é autorregressiva de ordem 1 (modelo AR(1)). A seguir, é encontrado explicitamente a solução geral de (24), bem como sua média e variância em equilíbrio.

Solução explícita da equação estocástica

Para simplificar a notação, omitimos o índice i e escrevemos

$$dX(t) = \kappa\big(m - X(t)\big)\,dt + \sigma\,dW(t), \qquad \kappa > 0.$$

Rearranjando os termos:

$$dX(t) + \kappa X(t)\,dt = \kappa m\,dt + \sigma\,dW(t).$$

Aplica-se o método do fator integrante, multiplicando ambos os lados por $e^{\kappa t}$:

$$e^{\kappa t}\,dX(t) + \kappa e^{\kappa t} X(t)\,dt = \kappa m e^{\kappa t}\,dt + \sigma e^{\kappa t}\,dW(t).$$

O lado esquerdo é a diferencial de $e^{\kappa t}X(t)$:

$$d\big(e^{\kappa t}X(t)\big) = \kappa m e^{\kappa t}\,dt + \sigma e^{\kappa t}\,dW(t).$$

Integra-se entre um instante inicial t_0 e um instante futuro $t_0 + \Delta t$:

$$e^{\kappa(t_0+\Delta t)}X(t_0+\Delta t) - e^{\kappa t_0}X(t_0) = \int_{t_0}^{t_0+\Delta t} \kappa m e^{\kappa s}\,ds + \int_{t_0}^{t_0+\Delta t} \sigma e^{\kappa s}\,dW(s).$$

O primeiro integral é determinístico:

$$\int_{t_0}^{t_0+\Delta t} \kappa m e^{\kappa s}\,ds = \kappa m \cdot \frac{e^{\kappa s}}{\kappa}\Big|_{t_0}^{t_0+\Delta t} = m\big(e^{\kappa(t_0+\Delta t)} - e^{\kappa t_0}\big).$$

Substituindo e dividindo por $e^{\kappa(t_0+\Delta t)}$, obtemos:

$$X(t_0+\Delta t) = e^{-\kappa\Delta t}X(t_0) + m\big(1 - e^{-\kappa\Delta t}\big) + \sigma \int_{t_0}^{t_0+\Delta t} e^{-\kappa(t_0+\Delta t - s)}\,dW(s). \tag{25}$$

Essa é a solução geral do processo de Ornstein–Uhlenbeck, e coincide com a expressão apresentada por Avellaneda e Lee (AVELLANEDA; LEE, 2008): o estado futuro $X(t_0+\Delta t)$ é uma combinação exponencial do estado inicial $X(t_0)$, do nível de equilíbrio m e de um termo aleatório que é uma integral estocástica.

Média condicional e incondicional

A integral estocástica em (25) tem média condicional nula, dado $X(t_0)$, pois

$$\mathbb{E}\left[\int_{t_0}^{t_0+\Delta t} e^{-\kappa(t_0+\Delta t - s)}\,dW(s) \,\Big|\, X(t_0)\right] = 0.$$

Portanto, a média condicional de $X(t_0+\Delta t)$ dado $X(t_0)$ é

$$\mathbb{E}\big[X(t_0+\Delta t) \,\big|\, X(t_0)\big] = e^{-\kappa\Delta t}X(t_0) + m\big(1 - e^{-\kappa\Delta t}\big). \tag{26}$$

A partir dessa expressão, podemos interpretar o *drift* (tendência) do processo: quando $X(t_0) < m$, o termo $m - X(t_0)$ é positivo e a média condicional

puxa o processo para cima; quando $X(t_0) > m$, o processo tende a se mover, em média, para baixo. Em termos diferenciais, para um intervalo muito pequeno Δt, temos aproximadamente

$$\mathbb{E}\big[X(t_0 + \Delta t) - X(t_0) \,\big|\, X(t_0)\big] \approx \kappa\big(m - X(t_0)\big)\,\Delta t,$$

o que recupera a forma do drift na equação estocástica (24).

Se o processo estiver em regime estacionário, a média incondicional $\mathbb{E}[X(t)]$ deve ser constante no tempo. Fazendo $t_0 \to -\infty$ ou, equivalentemente, tomando o limite $\Delta t \to \infty$ em (26), observa-se que

$$\lim_{\Delta t \to \infty} e^{-\kappa \Delta t} = 0,$$

e, portanto,

$$\lim_{\Delta t \to \infty} \mathbb{E}\big[X(t_0 + \Delta t) \,\big|\, X(t_0)\big] = m. \tag{27}$$

No equilíbrio estacionário, temos então

$$\mathbb{E}\big[X(t)\big] = m, \qquad \forall t. \tag{28}$$

Cálculo da variância e distribuição em equilíbrio

A variância condicional de $X(t_0 + \Delta t)$, dado $X(t_0)$, decorre novamente da expressão (25). Como o único termo aleatório é a integral estocástica e o processo é gaussiano, temos:

$$X(t_0 + \Delta t) \,\big|\, X(t_0) \sim \mathcal{N}\big(\mu(\Delta t),\, v(\Delta t)\big),$$

onde

$$\mu(\Delta t) = e^{-\kappa \Delta t} X(t_0) + m\big(1 - e^{-\kappa \Delta t}\big)$$

é a média condicional em (26), e

$$v(\Delta t) = \mathrm{Var}\left[\sigma \int_{t_0}^{t_0 + \Delta t} e^{-\kappa(t_0 + \Delta t - s)}\, dW(s)\right].$$

Utilizando a isometria de Itô, obtemos:

$$v(\Delta t) = \sigma^2 \int_{t_0}^{t_0 + \Delta t} e^{-2\kappa(t_0 + \Delta t - s)}\, ds.$$

Fazendo a mudança de variável $u = t_0 + \Delta t - s$, temos $du = -ds$ e, quando $s = t_0$, $u = \Delta t$; quando $s = t_0 + \Delta t$, $u = 0$. Logo:

$$\begin{aligned} v(\Delta t) &= \sigma^2 \int_0^{\Delta t} e^{-2\kappa u}\, du = \sigma^2 \left[-\frac{1}{2\kappa} e^{-2\kappa u} \right]_0^{\Delta t} \\ &= \sigma^2 \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \end{aligned}$$

Portanto,

$$\operatorname{Var}\big[X(t_0 + \Delta t) \,\big|\, X(t_0)\big] = \sigma^2 \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \tag{29}$$

No limite $\Delta t \to \infty$, o fator exponencial desaparece:

$$\lim_{\Delta t \to \infty} \left(1 - e^{-2\kappa \Delta t}\right) = 1,$$

e obtemos a variância em equilíbrio:

$$\operatorname{Var}\big[X(t)\big] = \lim_{\Delta t \to \infty} v(\Delta t) = \frac{\sigma^2}{2\kappa}. \tag{30}$$

Combinando (28) e (30), concluímos que a distribuição estacionária de $X(t)$ é normal:

$$X(t) \overset{d}{\sim} \mathcal{N}\left(m, \frac{\sigma^2}{2\kappa}\right), \qquad t \text{ em equilíbrio.}$$

Definindo o desvio-padrão estacionário como

$$\sigma_{\text{eq}} = \sqrt{\frac{\sigma^2}{2\kappa}}, \tag{31}$$

que é exatamente a forma utilizada no cálculo do s-score na Seção 5.1. Essa caracterização coincide com a encontrada por Avellaneda e Lee (AVELLANEDA; LEE, 2008) ao considerar o limite de longo prazo $\Delta t \to \infty$ na solução do processo de Ornstein–Uhlenbeck.

A.1 Discretização em tempo e modelo AR(1)

Na prática, o processo latente $X_i(t)$ não é diretamente observável em tempo contínuo. O que se observa empiricamente são retornos discretos das ações,

a partir dos quais se obtém, via regressão multifatorial em janelas móveis, a sequência de resíduos $\{\varepsilon_{i,n}\}_{n=1}^{L}$.

Mais precisamente, para cada ativo i, considera-se o modelo discreto

$$r_{i,n} = \alpha_i + \sum_{k=1}^{K} \beta_{ik} f_{k,n} + \varepsilon_{i,n}, \tag{32}$$

onde $r_{i,n}$ é o retorno observado no período n, $f_{k,n}$ são os retornos dos fatores e $\varepsilon_{i,n}$ representa a componente idiossincrática não explicada pelos fatores naquele período.

Sob a interpretação contínua apresentada anteriormente, o termo $\varepsilon_{i,n}$ pode ser visto como uma aproximação discreta do incremento do processo idiossincrático, isto é,

$$\varepsilon_{i,n} \;\approx\; \Delta X_i(t_n) \;=\; X_i(t_n) - X_i(t_{n-1}).$$

Com a relação entre os resíduos e o processo latente dada por

$$\varepsilon_{i,n} = X_{i,n} - X_{i,n-1}. \tag{33}$$

Então, pode-se escrever

$$X_{i,n} = X_{i,n-1} + \varepsilon_{i,n}. \tag{34}$$

Expandindo recursivamente, obtém-se:

$$X_{i,1} = X_{i,0} + \varepsilon_{i,1}, \tag{35}$$

$$X_{i,2} = X_{i,1} + \varepsilon_{i,2} = X_{i,0} + \varepsilon_{i,1} + \varepsilon_{i,2}, \tag{36}$$

$$X_{i,3} = X_{i,0} + \varepsilon_{i,1} + \varepsilon_{i,2} + \varepsilon_{i,3}, \tag{37}$$

$$\vdots$$

$$X_{i,k} = X_{i,0} + \sum_{j=1}^{k} \varepsilon_{i,j}. \tag{38}$$

Fixando $X_{i,0} = 0$, o que não implica perda de generalidade uma vez que o nível absoluto é irrelevante, segue que

$$X_{i,k} = \sum_{j=1}^{k} \varepsilon_{i,j}. \tag{39}$$

Dessa forma, o nível do processo X_i em tempo discreto é obtido pelo acúmulo dos resíduos ao longo do tempo.

Essa construção é consistente com o modelo contínuo

$$\frac{dS_i(t)}{S_i(t)} = \alpha_i \, dt + \sum_{k=1}^{K} \beta_{ik} F_k(t) \, dt + dX_i(t), \tag{40}$$

no qual a componente idiossincrática entra na forma diferencial $dX_i(t)$. Assim, enquanto os resíduos $\varepsilon_{i,n}$ capturam choques idiossincráticos de curto prazo, o processo acumulado $X_{i,k}$ representa o nível de desalinhamento relativo do ativo em relação ao equilíbrio implícito pelos fatores.

Uma vez construída a série $\{X_{i,k}\}$, assume-se que sua dinâmica pode ser aproximada, em tempo discreto, por um modelo autorregressivo de primeira ordem (AR(1)):

$$X_{i,k+1} = a_i + b_i X_{i,k} + \eta_{i,k+1}, \tag{41}$$

onde $\eta_{i,k}$ é um ruído branco com média zero. Esse modelo constitui a contraparte discreta do processo de Ornstein–Uhlenbeck e permite a estimação dos parâmetros $(\kappa_i, m_i, \sigma_i)$ do modelo contínuo.
Partindo da equação estocástica em tempo contínuo,

$$dX(t) = \kappa\big(m - X(t)\big) \, dt + \sigma \, dW(t),$$

a solução explícita em um intervalo de comprimento Δt, obtida na equação 25, pode ser escrita como

$$X(t + \Delta t) = e^{-\kappa \Delta t} X(t) + m\big(1 - e^{-\kappa \Delta t}\big) + \sigma \int_t^{t+\Delta t} e^{-\kappa(t+\Delta t - s)} \, dW(s). \tag{42}$$

Se definirmos os instantes discretos $t_n = t_0 + n \, \Delta t$ e escrevermos $X_n := X(t_n)$, a expressão acima torna-se

$$X_{n+1} = e^{-\kappa \Delta t} X_n + m\big(1 - e^{-\kappa \Delta t}\big) + \sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1} - s)} \, dW(s). \tag{43}$$

Comparando (43) com um modelo autorregressivo de ordem 1 (AR(1)),

$$X_{n+1} = a + b \, X_n + \zeta_{n+1}, \qquad n = 1, \ldots, L-1, \tag{44}$$

vemos que a identificação é imediata:

$$b = e^{-\kappa \Delta t}, \tag{45}$$

$$a = m\big(1 - e^{-\kappa \Delta t}\big) = m(1 - b), \tag{46}$$

$$\zeta_{n+1} = \sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1}-s)}\, dW(s). \tag{47}$$

Por construção, o termo ζ_{n+1} tem média condicional zero dado X_n, pois se trata de uma integral estocástica com integrando determinístico. Resta, então, calcular sua variância. Aplicando a isometria de Itô à definição (47), obtemos:

$$\begin{aligned} \mathrm{Var}(\zeta) &= \mathrm{Var}\left[\sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1}-s)}\, dW(s)\right] \\ &= \sigma^2 \int_{t_n}^{t_{n+1}} e^{-2\kappa(t_{n+1}-s)}\, ds. \end{aligned} \tag{48}$$

Fazendo a mudança de variável $u = t_{n+1} - s$, de modo que $ds = -du$, obtemos:

$$\begin{aligned} \mathrm{Var}(\zeta) &= \sigma^2 \int_0^{\Delta t} e^{-2\kappa u}\, du \\ &= \sigma^2 \left[-\frac{1}{2\kappa} e^{-2\kappa u}\right]_0^{\Delta t} \\ &= \sigma^2\, \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \end{aligned} \tag{49}$$

Assim, a relação entre os parâmetros discretos $(a, b, \mathrm{Var}(\zeta))$ do modelo AR(1) e os parâmetros contínuos (m, κ, σ) do processo de Ornstein–Uhlenbeck é dada por:

$$b = e^{-\kappa \Delta t}, \tag{50}$$

$$a = m\big(1 - e^{-\kappa \Delta t}\big) = m(1 - b), \tag{51}$$

$$\mathrm{Var}(\zeta) = \sigma^2\, \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \tag{52}$$

A partir dessas expressões, obtemos as fórmulas inversas de estimação:

$$\kappa = -\frac{1}{\Delta t}\log(b), \tag{53}$$

$$m = \frac{a}{1-b}, \tag{54}$$

$$\sigma = \sqrt{\mathrm{Var}(\zeta)\,\frac{2\kappa}{1-b^2}}. \tag{55}$$

Por convenção, utiliza-se $\Delta t = 1/252$ e reporta-se a velocidade de reversão em termos anualizados:

$$\kappa_{\mathrm{ann}} = -\log(b)\cdot 252. \tag{56}$$

Por fim, substituindo (52) na expressão da variância estacionária do processo discreto, obtemos uma forma particularmente simples para o desvio-padrão de equilíbrio σ_{eq} diretamente em função de b e $\mathrm{Var}(\zeta)$:

$$\sigma_{\mathrm{eq}} = \sqrt{\frac{\mathrm{Var}(\zeta)}{1-b^2}}. \tag{57}$$

B s-score

Cálculo dos s-scores em cada data

Para cada ativo, o método executa as seguintes etapas:

1. **Regressão multifatorial**: ajusta os retornos da ação em função dos fatores principais (PCA), obtendo os resíduos ε_i e os betas associados.

2. **Estimação do processo O–U**: s resíduos acumulados $X_{i,k} = \sum_{j\le k}\varepsilon_{i,j}$ são usados para ajustar um modelo AR(1), interpretado como discretização do processo O–U. Dessa estimação obtêm-se: $(\hat{m}_i, X_{i,T}, \widehat{\mathrm{Var}(\zeta_i)}, \hat{\kappa}_{i,\mathrm{ann}}, \hat{\sigma}_{i,\mathrm{eq}})$, onde $\hat{m}_i$ é o nível de equilíbrio, $X_{i,T}$ o estado atual do processo. $\hat{\kappa}_{i,\mathrm{ann}}$ o parâmetro de reversão anualizado, e $\hat{\sigma}_{i,\mathrm{eq}}$ o desvio-padrão estacionário.

3. **Filtro de reversão**: rejeitam-se ativos com reversão muito lenta ($\hat{\kappa}_{i,\mathrm{ann}} \le \kappa_{\mathrm{min}}$), conforme o critério proposto por Avellaneda e Lee (AVELLANEDA; LEE, 2008).

4. **Definição teórica do s-score**. No modelo contínuo de O–U, o s-score quantifica o desvio atual em unidades do desvio-padrão estacionário. Sua definição teórica é

$$s_i^{\text{raw}} = \frac{X_{i,T} - \hat{m}_i}{\hat{\sigma}_{i,\text{eq}}}. \tag{58}$$

5. **Centralização dos níveis de equilíbrio**. Em aplicações empíricas observa-se que a centralização dos equilíbrios em torno de sua média melhora o desempenho do indicador. Isso pode ser explicado devido que a distribuição dos equilíbrios estimados apresenta deslocamentos sistemáticos ao longo do tempo, gerando assimetria artificial nos s-scores, ou seja, os equilíbrios estimados $\hat{m}_i$ podem derivar coletivamente em diferentes janelas temporais, em resposta a mudanças de regime no mercado o que produz deslocamentos artificiais na distribuição transversal dos equilíbrios. Assim, substituí-se $\hat{m}_i$ por sua versão centralizada :

$$\hat{m}_i^* = \hat{m}_i - \bar{m}, \qquad \bar{m} = \frac{1}{N}\sum_j \hat{m}_j, \tag{59}$$

procedimento semelhante ao discutido no apêndice de Avellaneda e Lee, e que se mostrou empiricamente superior no presente estudo.

6. **Cálculo final do s-score**. Usando os equilíbrios centralizados, o s-score final é dado por

$$s_i = \frac{X_{i,T} - \hat{m}_i^*}{\hat{\sigma}_{i,\text{eq}}} = \frac{X_{i,T} - (\hat{m}_i - \bar{m})}{\hat{\sigma}_{i,\text{eq}}}. \tag{60}$$

C Evolução dos Parâmetros Otimizados

Neste apêndice são apresentadas as trajetórias temporais de alguns dos principais parâmetros selecionados ao longo do procedimento de otimização recorrente descrito na Seção 7.3. O objetivo dessa análise é investigar como a calibração ótima da estratégia varia ao longo do tempo e, com isso, avaliar em que medida o algoritmo de otimização responde a mudanças nas condições de mercado.

Diferentemente de uma parametrização fixa, o procedimento *walk-forward* adotado neste trabalho permite que a estratégia seja recalibrada periodicamente com base apenas nas informações disponíveis até cada instante. Assim, a sequência dos parâmetros selecionados ao longo dos anos pode ser interpretada como um retrato da adaptação do modelo aos diferentes regimes observados na amostra.

Nesta análise, são considerados quatro grupos de parâmetros particularmente relevantes para o comportamento da estratégia:

- o alvo de variância explicada acumulada utilizado na seleção adaptativa do número de componentes principais;
- os quantis que determinam os limiares de abertura e fechamento das posições;
- a frequência de rebalanceamento da carteira;
- o parâmetro mínimo de reversão à média, $\kappa_{\min}$.

Esses parâmetros foram escolhidos por representarem dimensões centrais da estratégia: estrutura fatorial, agressividade dos sinais, velocidade de atualização da carteira e exigência mínima de reversão dos ativos selecionados.

Alvo de variância explicada

A Figura 18 apresenta a evolução do parâmetro de variância explicada acumulada selecionado ao longo das sucessivas reotimizações. Esse parâmetro controla, de forma indireta, o número de componentes principais utilizados na decomposição dos retornos, uma vez que determina o percentual mínimo da variância total que deve ser capturado pelos fatores de PCA em cada janela.

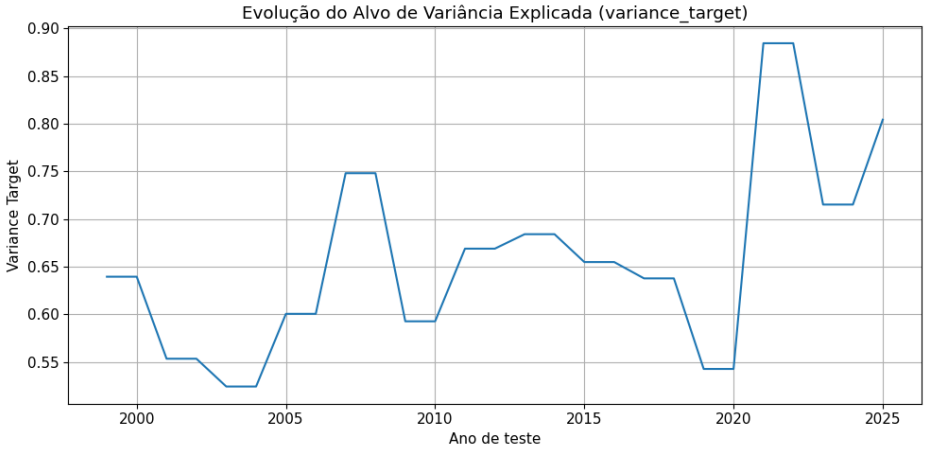

Figura 18: Evolução do alvo de variância explicada acumulada selecionado ao longo das reotimizações.

A variação desse parâmetro ao longo do tempo sugere que a complexidade fatorial ótima da estratégia não é constante. Em certos períodos, a otimização favorece níveis mais baixos de variância explicada, o que implica uma representação mais parcimoniosa dos fatores sistemáticos. Em outros momentos, o modelo seleciona alvos mais elevados, indicando a necessidade de capturar uma parcela maior da estrutura de covariância dos retornos.

Quantis dos limiares adaptativos

A Figura 19 mostra a evolução conjunta dos quantis utilizados para determinar os limiares adaptativos de abertura e fechamento das posições. Esses parâmetros controlam diretamente o grau de seletividade da estratégia, definindo o quão extremos os desvios precisam ser para gerar entradas e o quão próxima do centro da distribuição deve ser a reversão para motivar o encerramento das posições.

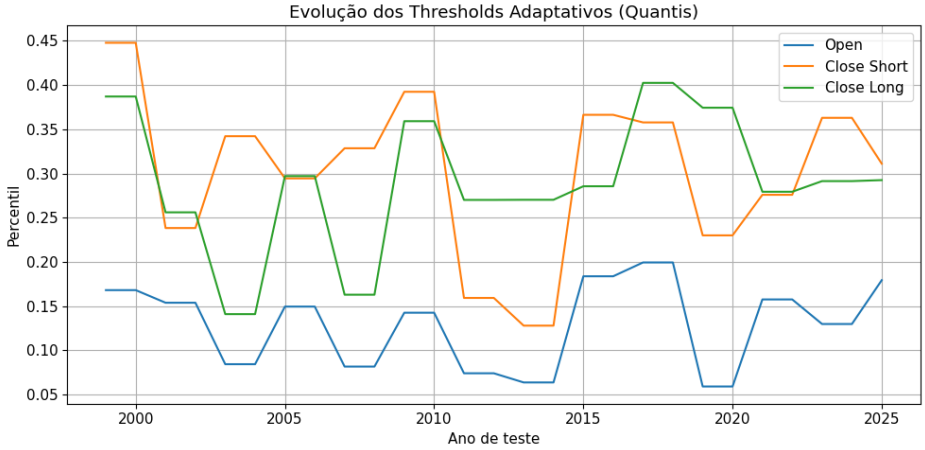

Figura 19: Evolução dos quantis utilizados nos limiares adaptativos de abertura e fechamento das posições ao longo das reotimizações.

As oscilações observadas nesses quantis indicam que o critério ótimo de negociação também varia com o regime de mercado. Em alguns períodos, a estratégia torna-se mais seletiva, exigindo sinais mais extremos para abertura de posições. Em outros, os limiares se aproximam mais do centro da distribuição, o que implica maior sensibilidade a desvios moderados. Esse comportamento reforça a ideia de que a intensidade dos sinais exploráveis pela estratégia não permanece constante ao longo do tempo.

Frequência de rebalanceamento

A Figura 20 apresenta a evolução da frequência de rebalanceamento selecionada em cada etapa de otimização. Esse parâmetro é particularmente importante porque afeta simultaneamente dois aspectos centrais da estratégia: sua capacidade de reagir rapidamente a novos sinais e seu nível de rotatividade, com impacto direto sobre os custos de transação.

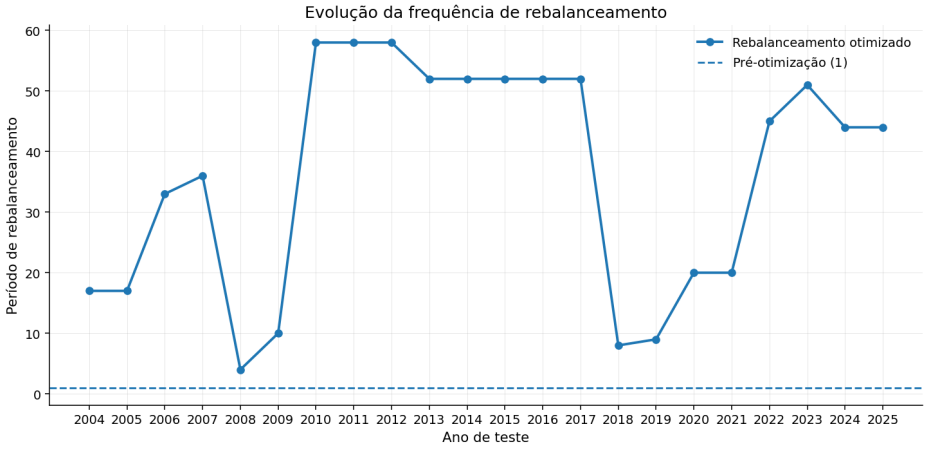

Figura 20: Evolução da frequência de rebalanceamento da carteira ao longo das reotimizações.

Quando a otimização escolhe frequências mais altas de rebalanceamento, a estratégia passa a reagir mais rapidamente às mudanças nos sinais de reversão à média, ao custo de maior turnover. Já frequências menores indicam preferência por uma atuação mais lenta e estável, possivelmente associada a sinais mais persistentes ou à necessidade de conter custos operacionais. Assim, esse gráfico fornece evidência sobre como o horizonte operacional ótimo da estratégia varia ao longo da amostra.

Parâmetro mínimo de reversão à média

Por fim, a Figura 21 mostra a evolução do parâmetro mínimo de reversão à média, $\kappa_{\min}$, utilizado como critério de elegibilidade dos ativos. Esse filtro impõe que apenas séries com velocidade mínima de reversão suficientemente elevada possam ser incorporadas ao portfólio.

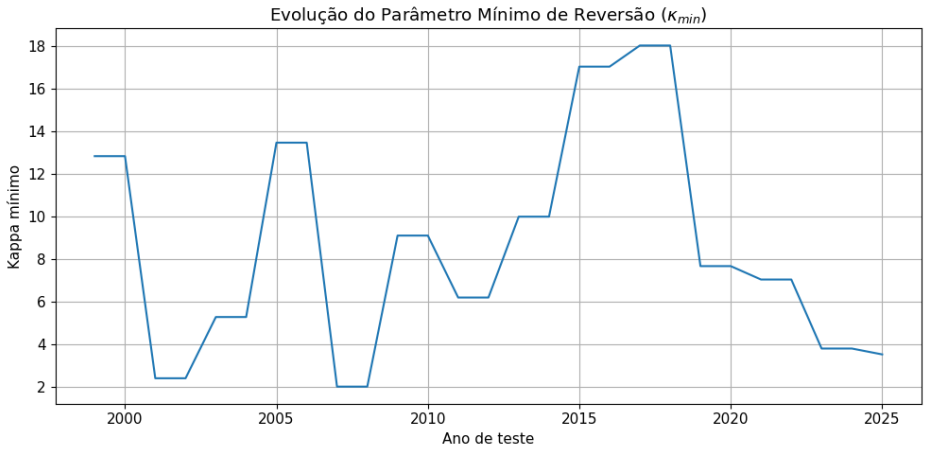

Figura 21: Evolução do parâmetro mínimo de reversão à média ($\kappa_{\min}$) ao longo das reotimizações.

A trajetória desse parâmetro sugere que a exigência de reversão imposta pela otimização também se altera com o tempo. Em alguns períodos, o modelo favorece filtros mais rígidos, exigindo que apenas ativos com reversão mais rápida sejam elegíveis. Em outros, a seleção torna-se mais permissiva, admitindo ativos com dinâmica mais lenta. Essa variação reflete mudanças na qualidade e na velocidade dos sinais disponíveis em cada regime de mercado.

De forma geral, a análise conjunta desses quatro parâmetros mostra que a otimização recorrente não apenas ajusta a intensidade dos sinais, mas também altera a estrutura fatorial, a velocidade operacional da estratégia e o grau de exigência em relação à reversão dos ativos. Em outras palavras, os resultados sugerem que a parametrização ótima da estratégia é sensível ao contexto de mercado e não pode ser vista como completamente estável ao longo do tempo.

Ao mesmo tempo, essa evidência ajuda a interpretar os resultados apresentados no corpo principal do trabalho: embora o procedimento de reotimização permita adaptar a estratégia a diferentes regimes, essa adaptabilidade, por si só, não foi suficiente para restaurar desempenho robusto no mercado norte-americano no longo prazo. Ainda assim, a análise das trajetórias dos parâmetros fornece informação útil sobre a dinâmica interna do modelo e sobre as dimensões em que a estratégia mostrou maior sensibilidade temporal.