Fundação Getulio Vargas
Escola de Matemática Aplicada

Sávio Vinícius Costa do Amaral

Estratégia de arbitragem estatística neutra ao mercado baseada em fatores de PCA e reversão à média

Rio de Janeiro
2025

Sávio Vinícius Costa do Amaral

Estratégia de arbitragem estatística neutra ao mercado baseada em fatores de PCA e reversão à média

Dissertação submetida à Escola de Matemática Aplicada como requisito parcial para a obtenção do grau de Mestre em Matemática Aplicada e Ciência de Dados.

Área de estudo: xx

Orientador: xx

Rio de Janeiro
2025

Agradecimentos

agradecimentos...

Resumo

O objetivo desta dissertação é desenvolver, implementar e avaliar empiricamente uma estratégia de arbitragem estatística neutra ao mercado baseada em fatores de PCA e reversão à média. Especificamente, pretende-se: (i) decompor o conjunto de retornos acionários em fatores principais (componentes sistemáticos) e resíduos (componente idiossincrática); (ii) modelar os resíduos como processos de reversão à média, gerando sinais de compra e venda compatíveis com a literatura de stat arb; e (iii) construir portfólios long–short neutros em relação ao mercado e aos fatores principais, avaliando seu desempenho out-of-sample sob custos de transação realistas. Ao fazê-lo, este trabalho procura contribuir para a literatura ao explorar, em detalhe, o papel de fatores de PCA em uma estratégia de arbitragem estatística neutra ao mercado, articulando os desenvolvimentos clássicos de Avellaneda & Lee (2008) e da literatura de pairs trading com a perspectiva mais recente de modelos em fatores e reversão à média em larga escala

Abstract

abstract...

Sumário

1 Introdução **7**

2 Revisão da Literatura **8**
2.1 Arbitragem Estatística e Fundamentos Teóricos 8
2.2 Pairs Trading e Cointegração 8
2.3 Avanços Recentes e Modelos de Alta Dimensionalidade 9

3 Análise de Componentes Principais (PCA) **10**
3.1 Abordagem PCA na Construção dos Fatores 11
3.2 Construção e retorno dos eigenportfólios 13

4 Modelo de valor relativo baseado em fatores principais de PCA **14**
4.1 Formulação contínua do modelo 15
4.2 O Processo de Ornstein–Uhlenbeck como modelo para desvios idiossincráticos 16
4.3 Componente idiossincrático e hipótese de reversão à média . . 17

5 Estratégia **18**
5.1 Cálculo do s-score 18
5.2 Regras de corte e definição de sinais 19
5.3 Esquema de pesos iguais por lado 21
5.4 Neutralidade ao mercado 22
5.5 Hedge multifatorial 24
5.6 Visão Geral da Estratégia 26

6 Cálculo do PnL **27**

7 Resultados do Backtesting **28**

8 Conclusão **29**

9 Referências **30**

10 Apêndices **32**

A Construção dos Fatores por PCA **32**

B Processo de Ornstein–Uhlenbeck: cálculo e estimação dos parâmetros **34**
B.1 Discretização em tempo e modelo AR(1) 37
B.2 Implementação numérica 40

1 Introdução

A arbitragem estatística, ou *Statistical Arbitrage* (StatArb), constitui um dos pilares da indústria de investimentos quantitativos moderna, sendo amplamente empregada por bancos de investimento, hedge funds e plataformas algorítmicas de alta complexidade (AVELLANEDA; LEE, 2008). Em contraste com abordagens discricionárias baseadas em análise fundamentalista, estratégias de StatArb são guiadas por sinais sistemáticos, regras explícitas e modelos matemáticos que procuram identificar e explorar ineficiências temporárias nos preços de ativos financeiros. Tais estratégias têm evoluído de métodos puramente estatísticos e econométricos para estruturas que incorporam técnicas de aprendizado de máquina e modelos de alta dimensionalidade (GUIJARRO-ORDONEZ; PELGER; ZANOTTI, 2022).

O princípio que sustenta a arbitragem estatística é a geração de retornos excessivos a partir de divergências transitórias entre ativos que, historicamente, apresentam relações estáveis. Assume-se que tais relações tendem a se restabelecer ao longo do tempo, tornando possível explorar estruturas de reversão à média e padrões de desequilíbrios momentâneos. Nesse contexto, esta dissertação contribui ao propor e avaliar uma estratégia de arbitragem estatística neutra ao mercado baseada em fatores principais extraídos por Análise de Componentes Principais (PCA) e modelagem de reversão à média.

A pesquisa desenvolvida busca: (i) decompor retornos acionários em fatores sistemáticos e idiossincráticos; (ii) modelar os resíduos como processos estocásticos de reversão à média; e (iii) construir portfólios long–short neutros ao mercado capazes de explorar oportunidades de arbitragem estatística no mercado acionário norte-americano. A abordagem proposta visa integrar rigor estatístico, neutralidade ao mercado e eficiência computacional, alinhando-se às diretrizes metodológicas mais recentes da literatura quantitativa.

Nos capítulos seguintes são apresentados os fundamentos teóricos da modelagem por PCA, os procedimentos de construção dos portfólios residuais, os métodos para extração dos sinais de reversão e, por fim, uma análise empírica detalhada do desempenho da estratégia proposta.

2 Revisão da Literatura

A literatura sobre arbitragem estatística constitui um corpo extenso e diversificado, abrangendo desde abordagens clássicas de *pairs trading* até modelos avançados baseados em fatores condicionais e aprendizado profundo. Esta seção apresenta um panorama das principais contribuições relevantes para esta dissertação.

2.1 Arbitragem Estatística e Fundamentos Teóricos

O conceito de arbitragem estatística dialoga diretamente com a Hipótese dos Mercados Eficientes (EMH), segundo a qual os preços dos ativos refletem toda a informação disponível. Em contraste, estratégias de StatArb partem da premissa de que desvios temporários e previsíveis podem surgir devido ao comportamento estocástico dos preços, permitindo capturar oportunidades de reversão (GATEV; GOETZMANN; ROUWENHORST, 2006; VIDYAMURTHY, 2004). Formalmente, Hogan et al. (HOGAN et al., 2004) definem uma estratégia de StatArb como um portfólio autossustentado, de custo inicial nulo, com expectativa assintoticamente positiva de retorno e probabilidade assintótica nula de perdas.

2.2 Pairs Trading e Cointegração

Entre as classes mais tradicionais de StatArb encontra-se o *pairs trading*. Desde o estudo seminal de Gatev, Goetzmann e Rouwenhorst (GATEV; GOETZMANN; ROUWENHORST, 2006), sabe-se que ativos economicamente semelhantes apresentam movimentos conjuntos, sendo possível explorar desvios temporários por meio de posições *long–short*. Avellaneda e Lee (AVELLANEDA; LEE, 2008) formalizam esse mecanismo utilizando modelos de cointegração e processos estacionários para o resíduo cointegrado, estabelecendo o arcabouço moderno para estratégias de reversão à média.

Modelos estocásticos, como o processo de Ornstein–Uhlenbeck, tornaram-se ferramentas fundamentais para representar spreads cointegrados e otimizar limiares operacionais (BERTRAM, 2010; ELLIOTT; HOEK; MALCOLM, 2005; ZENG; LEE, 2014). Estudos recentes, como Göncü e Akyildirim (GÖNCÜ; AKYILDIRIM, 2016), demonstram que, sob determinadas condições, um spread modelado como processo OU satisfaz formalmente critérios de arbitragem estatística.

2.3 Avanços Recentes e Modelos de Alta Dimensionalidade

A literatura recente trata a arbitragem estatística como um problema composto por três elementos: (i) construção de portfólios replicadores; (ii) extração de sinais temporais; e (iii) alocação ótima do portfólio. Nesse sentido, Guijarro-Ordonez, Pelger e Zanotti (GUIJARRO-ORDONEZ; PELGER; ZANOTTI, 2022) apresentam uma abordagem inovadora ao integrar aprendizado profundo, filtragem temporal e modelos de fatores (incluindo PCA e IPCA). Os autores mostram que resíduos fatoriais bem construídos tendem a ser aproximadamente estacionários, constituindo excelente base para extração de sinais de reversão e destacando que o componente idiossincrático é primordial para o desempenho em StatArb.

A presente dissertação dialoga diretamente com esta vertente ao explorar o uso de fatores de PCA na construção de portfólios residuais e na aplicação de modelos estocásticos de reversão à média em um contexto de neutralidade ao mercado.

3 Análise de Componentes Principais (PCA)

A Análise de Componentes Principais (PCA) é uma técnica estatística amplamente utilizada para reduzir a dimensionalidade de conjuntos de dados multivariados mantendo, tanto quanto possível, a variabilidade original (STANKOVIć et al., 2021; WANG et al., 2022). Em essência, o PCA projeta as variáveis observadas em um novo sistema de coordenadas formado por combinações lineares não correlacionadas, denominadas componentes principais. Esses componentes são ordenados de modo que o primeiro capture a maior parcela da variância total, o segundo capture a maior fração da variância remanescente, e assim sucessivamente.

A motivação central por trás do PCA é a identificação de estruturas latentes nos dados. Quando as variáveis originais exibem correlação significativa, é possível que uma parte substancial da informação seja explicada por poucas direções principais. Assim, o PCA atua como um mecanismo eficiente para condensar informações redundantes, contribuindo para o enfrentamento de problemas como sobreajuste, multicolinearidade e complexidade excessiva dos modelos (ANDERSEN, 2007). Em aplicações que envolvem alto número de covariáveis, essa redução é particularmente útil, pois facilita a interpretação dos padrões estruturais e diminui o risco de instabilidade nos ajustes estatísticos.

Do ponto de vista algébrico, considera-se um conjunto de p variáveis padronizadas, $X_1, X_2, \ldots, X_p$, com matriz de covariância amostral C. O PCA consiste em resolver o problema de autovalores

$$Cv_j = \lambda_j v_j, \tag{1}$$

onde v_j representa o j-ésimo autovetor associado ao autovalor λ_j. Cada autovetor define uma direção no espaço das variáveis originais, enquanto cada autovalor corresponde à variância explicada por essa direção. A j-ésima componente principal é dada pela combinação linear

$$Z_j = v_{1j}X_1 + v_{2j}X_2 + \cdots + v_{pj}X_p. \tag{2}$$

Os pesos v_{ij} são escolhidos de modo que os componentes principais satisfaçam três propriedades fundamentais: (i) são mutuamente não correlacionados; (ii) cada componente maximiza a variância explicada dentro do subconjunto restante; e (iii) a soma dos quadrados dos pesos de cada componente é igual a 1, garantindo normalização apropriada (TABACHNICK;

FIDELL, 2012).

Um aspecto importante na aplicação prática do PCA é a escolha do número de componentes a ser retido. Estudos aplicados utilizam critérios como o percentual acumulado de variância explicada, geralmente buscando capturar entre 80% e 90% da variância total (WANG et al., 2022). Esse processo evita tanto a inclusão de ruído quanto a perda excessiva de informação relevante. Graficamente, pode-se empregar o *scree plot*, enquanto métodos mais formais incluem critérios de Kaiser ou análises baseadas na distribuição dos eigenvalues.

A ortogonalidade entre as componentes é uma das principais vantagens do PCA. Como cada componente explica uma parcela distinta da variância, a técnica elimina explicitamente a redundância entre variáveis e produz fatores livres de correlação, o que é vantajoso em modelos que dependem de estabilidade e parcimônia. No entanto, é importante ressaltar que o PCA exige padronização prévia das variáveis, pois características com variância elevada podem influenciar de forma desproporcional a decomposição, introduzindo vieses indesejados (KUMAR, 2019).

No contexto desta dissertação, o PCA desempenha papel essencial ao decompor os retornos acionários em fatores sistemáticos e idiossincráticos. Os primeiros componentes principais capturam movimentos amplos do mercado e efeitos setoriais, enquanto os componentes de ordem superior tendem a refletir variabilidade específica de cada ativo. Assim, ao remover os fatores dominantes e trabalhar com os resíduos fatoriais, obtém-se uma série temporal mais próxima de estacionária, adequada para modelagem de reversão à média e construção de portfólios de arbitragem estatística. Essa abordagem permite reduzir exposição sistemática, aumentar a neutralidade de mercado e melhorar a qualidade dos sinais utilizados nas estratégias quantitativas subsequentes.

3.1 Abordagem PCA na Construção dos Fatores

A extração de fatores por meio da Análise de Componentes Principais (PCA) constitui a base da modelagem desenvolvida nesta dissertação. O objetivo é decompor os retornos acionários em combinações lineares ortogonais que capturam os principais movimentos sistemáticos do mercado, utilizando exclusivamente informação histórica de preços. Essa abordagem segue a formulação clássica apresentada em Jolliffe (2002) e encontra ampla aplicação em modelos quantitativos baseados em fatores.

Matriz de retornos e janela móvel

Seja

$$R = (R_{t,i})_{1\le t\le T,\, 1\le i\le N} \in \mathbb{R}^{T\times N},$$

a matriz de retornos diários, onde cada linha representa uma data e cada coluna um ativo. Para cada data t, reestimamos o PCA sobre uma janela móvel de M observações,

$$R^{(t)} = R_{t-M:t-1} \in \mathbb{R}^{M\times N},$$

preservando apenas os retornos mais recentes. Essa escolha evita que a estrutura de correlação seja afetada por informações excessivamente antigas e permite que os fatores reflitam condições de mercado dinâmicas.

Padronização dos ativos

Como diferentes ativos apresentam volatilidades distintas, é necessário padronizar cada coluna da janela. Para o ativo i, definimos

$$\mu_i^{(t)} = \frac{1}{M}\sum_{k=1}^{M} R_{k,i}^{(t)}, \qquad \sigma_i^{(t)} = \sqrt{\frac{1}{M-1}\sum_{k=1}^{M}\left(R_{k,i}^{(t)} - \mu_i^{(t)}\right)^2}.$$

A matriz padronizada $\widetilde{R}^{(t)}$ é dada por

$$\widetilde{R}_{k,i}^{(t)} = \frac{R_{k,i}^{(t)} - \mu_i^{(t)}}{\sigma_i^{(t)}},$$

de modo que cada ativo possui média zero e variância unitária dentro da janela. Essa etapa garante que o PCA identifique fatores associados à estrutura de correlação e não a diferenças de escala.

Matriz de correlação

Construímos a matriz de correlação empírica entre ativos:

$$\rho_{ij}^{(t)} = \frac{1}{M-1}\sum_{k=1}^{M} \widetilde{R}_{k,i}^{(t)}\,\widetilde{R}_{k,j}^{(t)},$$

ou de forma matricial,

$$\rho^{(t)} = \frac{1}{M-1}(\widetilde{R}^{(t)})^\top \widetilde{R}^{(t)}.$$

A matriz $\rho^{(t)}$ é simétrica e definida positiva, contendo toda a informação sobre movimentos conjuntos entre os ativos no período recente.

Decomposição PCA da matriz de correlação

Aplicamos o PCA sobre $\rho^{(t)}$ resolvendo o problema espectral

$$\rho^{(t)} v_j^{(t)} = \lambda_j^{(t)} v_j^{(t)}, \qquad j = 1, \ldots, N,$$

com autovalores ordenados como

$$\lambda_1^{(t)} \geq \lambda_2^{(t)} \geq \cdots \geq \lambda_N^{(t)} \geq 0.$$

Os maiores autovalores correspondem a direções que explicam a maior parcela da variância conjunta dos ativos. Assim,

- o primeiro componente geralmente representa o *fator de mercado*, pois captura um movimento comum a praticamente todos os ativos;
- componentes seguintes capturam padrões setoriais, temáticos ou estruturais;
- autovalores pequenos formam o *bulk spectrum*, típico de ruído.

Essa propriedade permite interpretar o PCA como um filtro que separa a estrutura sistemática dos movimentos idiossincráticos.

3.2 Construção e retorno dos eigenportfólios

Cada autovetor obtido pelo PCA define uma direção no espaço padronizado dos retornos, isto é, indica como combinar as séries que foram previamente normalizadas para terem variância unitária. Para utilizarmos esses vetores como pesos de portfólios reais, é necessário trazê-los de volta à escala original dos retornos, desfazendo a padronização aplicada durante o PCA. Esse

reescalonamento é feito dividindo cada coordenada do autovetor pelo desvio-padrão do respectivo ativo, resultando nos pesos brutos :

$$q_{j,i}^{(t)} = \frac{v_{j,i}^{(t)}}{\sigma_i^{(t)}},$$

e normalizamos para remover arbitrariedades de escala:

$$w_j^{(t)} = \frac{q_j^{(t)}}{\sum_{i=1}^{N} |q_{j,i}^{(t)}|}.$$

O vetor $w_j^{(t)}$ constitui um *eigenportfólio*: um portfólio sintético que reage exclusivamente ao j-ésimo componente principal.

Retornos fatoriais

O retorno do fator PCA no dia t é calculado como o retorno do eigenportfólio:

$$F_j(t) = \sum_{i=1}^{N} w_{j,i}^{(t)} R_{t,i} = R_{t,\cdot} \cdot w_j^{(t)}.$$

Os fatores obtidos em diferentes ordens são ortogonais entre si, o que facilita a decomposição dos retornos em componente sistemática e idiossincrática. Nesta dissertação utilizamos janelas móveis de $M = 60$ dias.

A separação entre variação sistemática (capturada pelos fatores) e variação específica (resíduos) é essencial para estratégias de arbitragem estatística, pois frequentemente os resíduos apresentam comportamento mais estacionário. A implementação integral do método descrito pode ser encontrada no **Apêndice A**, onde o código é apresentado e comentado, juntamente com um exemplo ilustrativo do formato de saída produzido pela função.

4 Modelo de valor relativo baseado em fatores principais de PCA

Um modelo de valor relativo é um modelo que avalia ativos comparando seu preço/retorno a benchmarks, pares ou fatores, buscando identificar desvios temporários da relação histórica entre eles. Nesta seção, apresentamos

o modelo de valor relativo utilizado para a precificação de ações a partir de retornos *excessivos* em relação a um conjunto de fatores sistemáticos. A formulação segue de perto a abordagem proposta por (AVELLANEDA; LEE, 2008), que usa fatores de risco construídos via Análise de Componentes Principais (PCA) obtidos diretamente da matriz de retornos das ações da amostra.

A ideia central é modelar o retorno de cada ação como a soma de dois componentes: (i) uma parte *sistemática*, explicada por um pequeno número de fatores comuns (os componentes principais), e (ii) um componente *idiossincrático*, que captura desvios específicos da ação em relação ao comportamento médio do mercado (ou do conjunto de ações) e que será explorado pela estratégia de arbitragem estatística.

4.1 Formulação contínua do modelo

Utilizaremos notação em tempo contínuo para descrever o modelo. Denote por $S_i(t)$ o preço da ação $i \in \{1, \ldots, N\}$ no instante t, medido em anos a partir de uma data inicial arbitrária. Denote por $F_k(t)$, com $k = 1, \ldots, K$, os *retornos instantâneos* (ou padronizados) dos fatores principais obtidos via PCA. Assumimos que os retornos instantâneos das ações satisfazem o sistema de equações diferenciais estocásticas

$$\frac{dS_i(t)}{S_i(t)} \;=\; \alpha_i\, dt \;+\; \sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt \;+\; dX_i(t), \qquad i = 1, \ldots, N, \tag{3}$$

onde:

- $\sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt$ é o componente sistemático do retorno da ação i, explicado pelos fatores principais de PCA;
- α_i é o *drift idiossincrático* da ação i, interpretado como a taxa média de retorno em excesso em relação à combinação de fatores;
- $dX_i(t)$ é o incremento de um processo estocástico estacionário que representa as flutuações idiossincráticas em torno da trajetória ditada pelos fatores.

A carga de risco da ação i ao fator k é capturada pelo coeficiente β_{ik}, de forma análoga ao que ocorre em modelos do tipo APT (*Arbitrage Pricing Theory*).

4.2 O Processo de Ornstein–Uhlenbeck como modelo para desvios idiossincráticos

Uma vez definida a estrutura multifatorial do retorno na Eq. (3), é necessário especificar a dinâmica estocástica do componente idiossincrático. Para capturar desvios transitórios em relação ao nível implícito pelos fatores de PCA, adotamos o processo de Ornstein–Uhlenbeck (O–U), amplamente utilizado na literatura de arbitragem estatística (AVELLANEDA; LEE, 2008).

O processo O–U é definido pela equação diferencial estocástica

$$dX_i(t) = \kappa_i \left(m_i - X_i(t)\right) dt + \sigma_i \, dW_i(t), \tag{4}$$

onde $\kappa_i > 0$ é a velocidade de reversão à média, m_i é o nível de equilíbrio de longo prazo do processo, σ_i é a difusão, e $W_i(t)$ é um movimento browniano padrão.

Este processo apresenta três propriedades essenciais para o presente modelo:

1. **Estacionaridade**: para $\kappa_i > 0$, o processo possui distribuição estacionária normal com média m_i e variância $\sigma_i^2/(2\kappa_i)$, permitindo interpretar desvios de $X_i(t)$ em relação a m_i como anomalias temporárias em relação ao valor de equilíbrio.

2. **Reversão à média**: quando $X_i(t)$ está distante de m_i, o termo determinístico $\kappa_i(m_i - X_i(t))$ induz uma força restauradora, característica fundamental para modelos de valor relativo.

3. **Linearidade e estimabilidade**: a versão discretizada do processo é equivalente a um modelo AR(1), o que permite estimar os parâmetros $(\kappa_i, m_i, \sigma_i)$ diretamente por regressão linear simples, facilitando a implementação empírica.

A escolha do processo de Ornstein–Uhlenbeck não é arbitrária: ela decorre das propriedades desejáveis que o modelo idiossincrático deve possuir neste contexto. Em primeiro lugar, o componente $X_i(t)$ deve ser estacionário, pois representa desvios transitórios em relação ao nível implícito pelos fatores; processos com tendência permanente ou variância explosiva seriam incompatíveis com a ideia de valor relativo. O processo O–U é a forma contínua mais simples de um processo estacionário gaussiano, garantindo variância finita e independência assintótica em relação às condições iniciais.

Além disso, a reversão à média é uma característica essencial para capturar a dinâmica típica de spreads de arbitragem estatística. Choques específicos de curto prazo — como fluxos temporários, efeitos de liquidez ou ajustes idiossincráticos — produzem deslocamentos que tendem a se dissipar ao longo do tempo, comportamento que é descrito precisamente pelo termo restaurador $\kappa_i(m_i - X_i(t))$.

Do ponto de vista empírico, a discretização do processo O–U é equivalente a um modelo AR(1), que se ajusta de forma robusta aos resíduos resultantes da regressão multifatorial. Assim, o modelo combina simplicidade analítica e facilidade de estimação: os parâmetros $(\kappa_i, m_i, \sigma_i)$ podem ser obtidos por regressão linear simples, e a estrutura resultante permite medir o desvio relativo de cada ativo por meio de estatísticas padronizadas, como o s-score, utilizadas diretamente na construção dos sinais de trading.

Todas as etapas de obtenção dessas expressões, desde a solução do processo, passando pelo cálculo da média e variância estacionárias, até os procedimentos de estimação dos parâmetros são apresentadas de forma detalhada no **Apêndice B**

4.3 Componente idiossincrático e hipótese de reversão à média

Retomando o modelo da Eq. (3), o termo

$$\alpha_i \, dt + dX_i(t)$$

representa a parcela do retorno da ação que não é explicada pelos fatores principais extraídos via PCA. Interpretamos esse termo como o componente idiossincrático do ativo.

O parâmetro α_i descreve a tendência média de retorno em excesso da ação em relação aos fatores. Já o processo $X_i(t)$ mede o desvio instantâneo do preço relativo da ação em relação ao nível sugerido pelos fatores sistemáticos. Desvios persistentes em $X_i(t)$ são interpretados como deslocamentos temporários de preço, oriundos de choques de liquidez, sobre-reação ou fluxos específicos da ação.

Como discutido na Seção 4.2, assumimos que $X_i(t)$ segue um processo de Ornstein–Uhlenbeck, o que implica que tais desvios tendem a retornar a um nível de equilíbrio m_i ao longo do tempo. Assim, a hipótese fundamental é que o preço relativo apresenta uma componente transiente que, ao se afastar muito do equilíbrio, sinaliza oportunidades de arbitragem estatística.

Em síntese, o componente idiossincrático fornece o elo entre (i) o modelo multifatorial baseado em PCA e (ii) a geração de sinais de reversão utilizados na estratégia empírica de valor relativo.

5 Estratégia

Nesta seção descrevemos a estratégia de arbitragem estatística construída a partir do modelo de valor relativo apresentado na Seção 4. Recordamos brevemente os elementos essenciais do modelo utilizado. Seja $S_i(t)$ o preço da ação $i \in \{1, \ldots, N\}$ no instante t. De acordo com o modelo multifatorial em tempo contínuo descrito na Eq. (3), o retorno da ação satisfaz esse sistema de equação diferencial estocástica

$$\frac{dS_i(t)}{S_i(t)} \;=\; \alpha_i\, dt \;+\; \sum_{k=1}^{K} \beta_{ik}\, F_k(t)\, dt \;+\; dX_i(t), \tag{5}$$

onde $F_k(t)$ denota o retorno do k-ésimo fator principal de PCA, β_{ik} é a sensibilidade da ação i a esse fator, α_i é o retorno médio em excesso e $X_i(t)$ descreve o desvio idiossincrático em relação ao nível implícito pelos fatores.

Assumimos que $X_i(t)$ segue um processo de Ornstein–Uhlenbeck conforme Eq. (4):

$$dX_i(t) = \kappa_i\,(m_i - X_i(t))\, dt + \sigma_i\, dW_i(t), \tag{6}$$

com $\kappa_i > 0$, $m_i \in \mathbb{R}$, $\sigma_i > 0$ e $W_i(t)$ um movimento browniano padrão. Nesse enquadramento, m_i representa o nível de equilíbrio de longo prazo do desvio idiossincrático e κ_i quantifica a velocidade com que a ação tende a reverter a esse nível após choques transitórios.

A estratégia explorará desvios significativos entre $X_i(t)$ e m_i, devidamente padronizados, para definir sinais de compra e venda.

5.1 Cálculo do s-score

O s-score é um indicador adimensional que mede o quão distante o processo idiossincrático $X_i(t)$ se encontra de seu nível de equilíbrio, em unidades de desvio-padrão estacionário. Seguindo a literatura de arbitragem estatística, consideramos a distribuição estacionária do processo O–U na Eq. (6). Para $\kappa_i > 0$, essa distribuição é normal com média m_i e variância

$$\mathrm{Var}[X_i(\infty)] = \frac{\sigma_i^2}{2\kappa_i}.$$

Definimos, portanto, o desvio-padrão de equilíbrio como

$$\sigma_{i,\mathrm{eq}} = \sqrt{\frac{\sigma_i^2}{2\kappa_i}}.$$

O s-score da ação i no instante t é dado por

$$s_i(t) = \frac{X_i(t) - m_i}{\sigma_{i,\mathrm{eq}}}. \tag{7}$$

Valores elevados (em módulo) de $s_i(t)$ indicam que a ação se encontra em uma região estatisticamente rara, quando comparada à distribuição de equilíbrio implícita pelo processo O–U. Assim, por construção:

- $s_i(t) \gg 0$ sugere que o preço relativo da ação está *supervalorizado* em relação ao equilíbrio;
- $s_i(t) \ll 0$ sugere que o preço relativo está *subvalorizado*.

Na implementação discreta, $X_i(t)$ é estimado a partir de resíduos $\varepsilon_i(\tau)$ da regressão multifatorial em janelas deslizantes, e os parâmetros $(\kappa_i, m_i, \sigma_i)$ são obtidos via ajuste de um modelo AR(1) equivalente, conforme discutido anteriormente. O s-score constitui, portanto, o elo entre a dinâmica estocástica idiossincrática e a regra de trading.

5.2 Regras de corte e definição de sinais

A estratégia utiliza o s-score como estatística central para detectar desvios significativos em relação ao nível de equilíbrio implícito pelo processo de Ornstein–Uhlenbeck. Com base nesses desvios, definimos regras de entrada e saída que exploram a hipótese de reversão à média.

Para evitar operar em regiões dominadas por ruído, pequenos deslocamentos estatisticamente irrelevantes, introduzimos quatro parâmetros de corte, distintos para abertura e encerramento de posições:

$$s_{\mathrm{bo}} < 0, \qquad s_{\mathrm{so}} > 0, \qquad s_{\mathrm{bc}} > 0, \qquad s_{\mathrm{sc}} < 0,$$

onde:

- s_{bo} (*buy-to-open*) é o limiar negativo para abertura de posições compradas;

- s_{so} (*sell-to-open*) é o limiar positivo para abertura de posições vendidas;
- s_{bc} (*buy-to-close*) é o limiar positivo para encerramento de posições vendidas;
- s_{sc} (*sell-to-close*) é o limiar negativo para encerramento de posições compradas.

Dessa forma, o conjunto de regras de negociação pode ser escrito como:

$$\text{abrir compra se } s_i(t) < s_{\mathrm{bo}}, \qquad \text{abrir venda se } s_i(t) > s_{\mathrm{so}},$$

$$\text{fechar venda se } s_i(t) < s_{\mathrm{bc}}, \qquad \text{fechar compra se } s_i(t) > s_{\mathrm{sc}}.$$

Os valores numéricos de cada corte são determinados empiricamente, por meio de simulações históricas, levando em conta a frequência de operações, custos de transação e robustez estatística dos desvios observados.

A motivação para restringir a abertura de posições a valores extremos do s-score decorre diretamente da interpretação do processo idiossincrático. Como discutido na Seção 4.2, $X_i(t)$ deve oscilar em torno de um equilíbrio m_i, e grandes desvios são eventos relativamente raros sob a distribuição estacionária. Assim, ao abrir posições apenas quando $s_i(t)$ excede um limiar suficientemente elevado, a estratégia foca nos episódios que interpretamos como potenciais oportunidades de reversão à média.

Por outro lado, o encerramento das posições é ativado quando o s-score retorna para valores próximos de zero (em torno dos cortes s_{bc} e s_{sc}). Essa regra é coerente com a dinâmica prevista pelo processo de Ornstein–Uhlenbeck: em equilíbrio, espera-se que a maior parte do tempo $X_i(t)$ permaneça próxima de sua média. Assim, fechar posições quando $s_i(t)$ retorna à região central captura a reversão esperada, ao mesmo tempo que evita manter posições excessivamente longas em um regime em que o sinal já perdeu valor preditivo.

A lógica subjacente é, portanto, detectar ações cujos desvios idiossincráticos se afastaram de maneira estatisticamente significativa do equilíbrio, abrir posições apostando na reversão desses desvios, e encerrá-las quando o processo retornar a uma vizinhança neutra. Esse ciclo de entrada e saída está intimamente ligado à *escala temporal de reversão* do processo de O–U, frequentemente caracterizada pelo parâmetro $\tau_i = 1/\kappa_i$, interpretado como o tempo característico para o retorno ao equilíbrio.

Em suma, os cortes traduzem a dinâmica de reversão à média em regras de negociação disciplinadas, garantindo que a estratégia opere apenas diante

de desvios estatisticamente relevantes e seja encerrada quando o sinal perde significância.

A partir das regras de corte, cada ativo é classificado no instante t como candidato a compra, venda ou sem posição:

comprar se $s_i(t) < s_{\text{bo}}$, vender se $s_i(t) > s_{\text{so}}$, caso contrário, sem posição.

Isso define dois conjuntos de ativos:

$$\mathcal{L}(t) = \{i : s_i(t) < s_{\text{bo}}\}, \qquad \mathcal{S}(t) = \{i : s_i(t) > s_{\text{so}}\},$$

correspondentes aos sinais positivos (*long*) e negativos (*short*). Em termos de sinal bruto,

$$\tilde{w}_i(t) = \begin{cases} +1, & i \in \mathcal{L}(t), \\ -1, & i \in \mathcal{S}(t), \\ 0, & \text{caso contrário.} \end{cases}$$

No entanto, tais sinais precisam ser convertidos em pesos financeiros que controlem a exposição da carteira

5.3 Esquema de pesos iguais por lado

As regras de corte descritas na Seção 5.2 produzem, a cada instante t, um conjunto de ativos candidatos a posições compradas e vendidas, de acordo com a magnitude e o sinal do desvio idiossincrático medido pelo s-score. Para transformar esses sinais discretos em um portfólio financeiro, é necessário especificar como o capital será distribuído entre os ativos selecionados.

Adotamos um esquema de *pesos iguais por lado*, no qual a totalidade do capital alocado no bloco comprado e no bloco vendido é distribuída uniformemente entre os ativos pertencentes a cada conjunto. Seja

$$\mathcal{L}(t) = \{i : s_i(t) < s_{\text{bo}}\}, \qquad \mathcal{S}(t) = \{i : s_i(t) > s_{\text{so}}\},$$

correspondendo, respectivamente, aos sinais de compra e de venda. Os pesos são definidos como:

$$w_i(t) = \frac{1}{|\mathcal{L}(t)|}, \qquad i \in \mathcal{L}(t), \tag{8}$$

$$w_i(t) = -\frac{1}{|\mathcal{S}(t)|}, \qquad i \in \mathcal{S}(t), \tag{9}$$

$$w_i(t) = 0, \qquad \text{caso contrário.} \tag{10}$$

Isso garante que:

$$\sum_{i \in \mathcal{L}(t)} w_i(t) = 1, \qquad \sum_{i \in \mathcal{S}(t)} w_i(t) = -1,$$

tornando a carteira estritamente *dollar-neutral*: a exposição comprada compensa exatamente a exposição vendida, e a posição líquida em valor é nula, ou seja, $\sum w_i(t) = 0$.

A escolha por pesos iguais por lado é motivada por duas razões principais:

1. **Evitar concentração indevida.** A normalização uniforme impede que a carteira seja dominada por poucos ativos com s-scores extremos, promovendo uma distribuição equilibrada do risco e garantindo que a estratégia explore um conjunto diversificado de oportunidades de reversão à média.

2. **Neutralidade direcional em valor.** Ao impor uma exposição comprada de $+1$ e uma exposição vendida de -1, a estratégia não carrega nenhuma aposta sistemática em relação ao movimento agregado do mercado. Movimentos amplos no índice tendem a impactar long e short de maneira simétrica, de modo que o rendimento líquido decorra principalmente da dinâmica relativa entre os ativos — exatamente a fonte de retorno que a metodologia busca explorar.

Esse esquema de pesos estabelece a base estrutural para que, nas etapas seguintes, possamos impor neutralidade em relação aos fatores sistemáticos por meio de um *hedge* multifatorial.

5.4 Neutralidade ao mercado

A etapa anterior introduziu o esquema de pesos iguais por lado, no qual a exposição comprada totaliza $+1$ e a exposição vendida totaliza -1, resultando em uma carteira essencialmente *dollar-neutral*. Essa é a primeira camada de neutralização necessária em uma estratégia long–short de valor relativo, pois garante que o portfólio não carregue, em termos de valor, nenhuma aposta direcional explícita em relação ao mercado agregado.

No entanto, a neutralidade em valor é apenas uma condição preliminar. Mesmo com $\sum_i w_i(t) = 0$, o portfólio pode permanecer sensível aos fatores sistemáticos que explicam grande parte da covariância entre os retornos, como

os componentes principais extraídos por PCA. Em outras palavras, diferenças estruturais entre os ativos comprados e vendidos podem gerar *beta líquido* não nulo.

Para que a estratégia seja uma verdadeira arbitragem estatística, isto é, para que seu desempenho reflita exclusivamente a dinâmica idiossincrática associada à reversão à média, é necessário impor neutralidade aos fatores sistemáticos.

A ideia de neutralidade ao mercado pode ser formalizada a partir de um modelo multifatorial clássico. Suponha que o retorno do ativo i seja dado por

$$R_i(t) = \sum_{j=1}^{m} \beta_{ij}(t)\, F_j(t) + \tilde{R}_i(t), \tag{11}$$

onde $F_j(t)$ são fatores sistemáticos (como o fator de mercado, fatores setoriais ou fatores extraídos via PCA) e $\tilde{R}_i(t)$ é o componente idiossincrático. Seja $w_i(t)$ o peso do ativo i no portfólio em t; o retorno da carteira é então

$$R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, R_i(t). \tag{12}$$

Substituindo (11), obtemos

$$\begin{aligned} R^{\text{port}}(t) &= \sum_{i=1}^{N} w_i(t) \left[\sum_{j=1}^{m} \beta_{ij}(t)\, F_j(t) + \tilde{R}_i(t) \right] \\ &= \sum_{j=1}^{m} \left[\sum_{i=1}^{N} w_i(t)\, \beta_{ij}(t) \right] F_j(t) + \sum_{i=1}^{N} w_i(t)\, \tilde{R}_i(t). \end{aligned} \tag{13}$$

Definimos a *exposição agregada* do portfólio ao fator j como

$$\beta_j^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, \beta_{ij}(t). \tag{14}$$

Um portfólio é *market-neutral* (ou, mais geralmente, *factor-neutral*) quando suas projeções sobre os fatores são nulas, isto é,

$$\beta_j^{\text{port}}(t) = 0, \qquad j = 1, \ldots, m. \tag{15}$$

Nessas condições, a decomposição (13) se reduz a

$$R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, \tilde{R}_i(t), \tag{16}$$

ou seja, o retorno da carteira passa a depender exclusivamente dos componentes idiossincráticos $\tilde{R}_i(t)$.

Esse resultado esclarece por que a neutralidade ao mercado é central em estratégias baseadas em reversão à média: se o portfólio carregasse beta residual em relação a algum fator $F_j(t)$, parte de seu desempenho poderia ser explicada por movimentos amplos do mercado ou de fatores setoriais, e não pela dinâmica de reversão dos resíduos. Em outras palavras, o portfólio deixaria de ser uma aposta puramente relativa e passaria a incorporar, de forma não controlada, risco sistemático.

É importante notar que neutralidade em termos de *valor*, por exemplo, manter a soma dos pesos comprados aproximadamente igual, em magnitude, à soma dos pesos vendidos, é uma condição necessária, mas não suficiente. Uma carteira pode ser dollar-neutral e, ainda assim, estar comprada em ativos com betas médios elevados e vendida em ativos com betas médios reduzidos, gerando um beta líquido positivo em relação ao mercado. Isso motiva a escolha cuidadosa do esquema de pesos e, em seguida, a aplicação de um hedge multifatorial explícito, como discutido nas subseções seguintes.

5.5 Hedge multifatorial

Como discutido na Seção 5.4, um portfólio long–short pode satisfazer $\sum_i w_i(t) = 0$ e, ainda assim, apresentar betas agregados não nulos em relação aos fatores extraídos via PCA. Seja, para cada data t,

$$w(t) = \big(w_1(t), \ldots, w_N(t)\big)$$

o vetor de pesos da carteira sobre as ações, e seja $\beta_{ik}(t)$ a carga da ação i no fator k na data t.

A exposição agregada da carteira a cada fator principal k é dada por

$$E_k(t) = \sum_{i=1}^{N} w_i(t)\, \beta_{ik}(t), \qquad k = 1, \ldots, K. \tag{17}$$

Em notação vetorial, podemos escrever

$$E(t) = \big(E_1(t), \ldots, E_K(t)\big) = w(t)^\top B(t),$$

em que $B(t)$ é a matriz $N \times K$ de betas, ou seja, o vetor de exposições fatoriais é simplesmente o produto do vetor de pesos pelas colunas de betas.

O hedge multifatorial consiste em introduzir posições adicionais diretamente nos fatores de PCA (implementados como eigenportfólios) com o objetivo de cancelar essas exposições. Denotando por $h_k(t)$ o peso da carteira no k-ésimo fator principal, impomos que a exposição líquida após o hedge seja nula:

$$E_k^{\text{hedged}}(t) = E_k(t) + h_k(t) = 0, \qquad k = 1, \ldots, K.$$

Daqui, segue imediatamente que a escolha natural é

$$h_k(t) = -\,E_k(t) = -\sum_{i=1}^{N} w_i(t)\,\beta_{ik}(t), \qquad k = 1, \ldots, K. \tag{18}$$

Em forma compacta:

$$h(t) = -\,E(t) = -\,w(t)^\top B(t).$$

Na implementação numérica, o hedge é obtido calculando-se, para cada data, o vetor de exposições fatoriais $E(t)$ definido em (17), e atribuindo ao portfólio uma posição de igual magnitude e sinal oposto nos próprios fatores principais. Isso produz, ao longo do tempo, uma série de pesos alocados em cada fator de PCA, cuja única finalidade é cancelar as exposições sistemáticas induzidas pelas posições nas ações, sem alterar a estrutura relativa das posições geradas pelos sinais de reversão à média.

Uma vez aplicado o hedge, os pesos efetivos da estratégia podem ser decompostos em dois blocos:

- o bloco de ações, com pesos $w_i(t)$, construído a partir dos sinais de reversão à média e do esquema de pesos iguais por lado;
- o bloco de fatores, com pesos $h_k(t)$, cuja única função é cancelar as exposições sistemáticas $E_k(t)$.

O retorno da carteira passa a ser dado por

$$R^{\text{port}}(t) = \sum_{i=1}^{N} w_i(t)\, R_i(t) + \sum_{k=1}^{K} h_k(t)\, R_k^F(t), \tag{19}$$

onde $R_k^F(t)$ é o retorno do k-ésimo fator principal (eigenportfólio) no intervalo $[t-1, t]$. Pela construção em (18), as parcelas associadas aos fatores sistemáticos se cancelam em primeira ordem, e o retorno resultante pode ser visto, em boa aproximação, como função apenas dos componentes idiossincráticos dos ativos.

5.6 Visão Geral da Estratégia

A estratégia proposta pode ser resumida em quatro etapas principais:

1. **Modelagem multifatorial e obtenção dos desvios idiossincráticos.** Os retornos das ações são decompostos em uma componente sistemática, explicada pelos fatores principais extraídos via PCA, e um componente residual $X_i(t)$, interpretado como desvio idiossincrático em relação ao nível implícito pelos fatores.

2. **Reversão à média e cálculo do s-score.** Cada processo residual $X_i(t)$ é modelado como Ornstein–Uhlenbeck, permitindo estimar seu ponto de equilíbrio e sua variabilidade estacionária. O s-score quantifica, em unidades padronizadas, o afastamento atual do ativo em relação ao equilíbrio, servindo como indicador de extremidade do desvio.

3. **Regras de entrada e saída baseadas em cortes.** Limiares pré-definidos sobre o s-score determinam a abertura de posições compradas ou vendidas, bem como seu encerramento, explorando exclusivamente episódios de desvios estatisticamente relevantes e sua posterior reversão à média.

4. **Construção do portfólio e neutralidade ao risco sistemático.** As posições selecionadas são convertidas em um portfólio long–short com pesos iguais por lado, garantindo neutralidade em valor. Em seguida, aplica-se um hedge multifatorial diretamente nos fatores de PCA, anulando exposições sistemáticas residuais e concentrando o desempenho da estratégia na componente idiossincrática.

Em conjunto, essas etapas definem uma metodologia de valor relativo orientada à reversão à média, cuja performance busca refletir exclusivamente a dinâmica idiossincrática dos ativos, minimizando a influência de movimentos amplos do mercado e de fatores comuns.

6 Cálculo do PnL

Por fim, descrevemos o cálculo do resultado financeiro da estratégia. Considere horizontes discretos $t = 0, 1, 2, \ldots$ correspondentes, por exemplo, a dias de negociação. Denote por $R_i(t)$ o retorno (simples ou logarítmico, conforme convenção adotada) da ação i entre $t-1$ e t, e por $R_k^F(t)$ o retorno do fator k no mesmo intervalo.

Seja $w_i(t-1)$ o peso da ação i na carteira ao final do dia $t-1$, e $h_k(t-1)$ o peso de hedge no fator k. O retorno bruto da carteira no dia t é dado por

$$R_{\text{port}}^{\text{bruto}}(t) = \sum_{i=1}^{N} w_i(t-1)\, R_i(t) + \sum_{k=1}^{K_{\text{hedge}}} h_k(t-1)\, R_k^F(t). \tag{20}$$

Para obter o PnL líquido, é necessário descontar os custos de transação associados ao rebalanceamento da carteira. Adotamos um custo proporcional fixo de $\epsilon = 5$ bps por unidade de capital movimentado, isto é, $\epsilon = 0{,}05$ custo por lado (abrir ou fechar).

Esse custo incide linearmente sobre a variação absoluta dos pesos entre $t-1$ e t, tanto no bloco de ações quanto no bloco de hedge. Assim, cada ajuste na carteira representa um custo proporcional ao montante de capital movimentado.

A variação absoluta de peso na ação i entre $t-1$ e t é $|\Delta w_i(t)| = |w_i(t) - w_i(t-1)|$, e definimos analogamente $|\Delta h_k(t)|$ para os pesos de hedge. O custo de transação total no dia t é então modelado como

$$C_{\text{tx}}(t) = \epsilon \left(\sum_{i=1}^{N} |\Delta w_i(t)| + \sum_{k=1}^{K_{\text{hedge}}} |\Delta h_k(t)| \right). \tag{21}$$

Além disso, a estratégia assume que 100% do patrimônio é alocado a cada dia. A distribuição do capital é inteiramente determinada pelos pesos vigentes no instante t.

O retorno líquido da estratégia no dia t é

$$R_{\text{port}}^{\text{líquido}}(t) = R_{\text{port}}^{\text{bruto}}(t) \; - \; C_{\text{tx}}(t). \tag{22}$$

A partir da série temporal de $R_{\text{port}}^{\text{líquido}}(t)$, calculamos o PnL acumulado e as estatísticas de desempenho usuais, tais como retorno anualizado, volatilidade, índice de Sharpe e *max drawdown*. Essas medidas permitem avaliar em que medida a hipótese de reversão à média dos componentes idiossincráticos, capturada pelo modelo O–U e operacionalizada via s-scores, se traduz em ganhos econômicos após custos de transação e sob restrições de neutralidade sistemática.

7 Resultados do Backtesting

8 Conclusão

conclusão

9 Referências

Referências

ANDERSEN, M. S. An introductory note on the environmental economics of the circular economy. *Sustainability Science*, v. 2, n. 1, p. 133–140, 2007. ISSN 1862-4057. Disponível em: ⟨https://doi.org/10.1007/s11625-006-0013-6⟩.

AVELLANEDA, M.; LEE, J.-H. Statistical arbitrage in the u.s. equities market. *SSRN Electronic Journal*, 2008. Disponível em: ⟨https://ssrn.com/abstract=1153505⟩.

BERTRAM, W. Analytic solutions for optimal statistical arbitrage trading. *Physica A: Statistical Mechanics and its Applications*, v. 389, n. 11, p. 2234–2243, 2010.

ELLIOTT, R. J.; HOEK, J. V. D.; MALCOLM, W. P. Pairs trading. *Quantitative Finance*, v. 5, n. 3, p. 271–276, 2005.

GATEV, E.; GOETZMANN, W. N.; ROUWENHORST, K. G. Pairs trading: Performance of a relative-value arbitrage rule. *Review of Financial Studies*, v. 19, n. 3, p. 797–827, 2006.

GÖNCÜ, A.; AKYILDIRIM, E. Statistical arbitrage with pairs trading. *International Review of Finance*, v. 16, n. 2, p. 307–319, 2016.

GUIJARRO-ORDONEZ, J.; PELGER, M.; ZANOTTI, G. Deep learning statistical arbitrage. *Working Paper*, 2022. First draft: 2019. This draft: 2022. Disponível em: ⟨https://papers.ssrn.com/sol3/papers.cfm?abstract_id=xxxxxxx⟩.

HOGAN, S. et al. Testing market efficiency using statistical arbitrage with applications to momentum and value strategies. *Journal of Financial Economics*, v. 73, n. 3, p. 525–565, 2004.

KUMAR, N. *Advantages and Disadvantages of Principal Component Analysis in Machine Learning*. 2019. ⟨http://theprofessionalspoint.blogspot.com/2019/03/advantages-anddisadvantages-of_4.html⟩. Accessed: 2021-04-15.

STANKOVIć, J. J. et al. An integrated approach of pca and promethee in spatial assessment of circular economy indicators. *Waste Management*, v. 128, p. 154–166, 2021. ISSN 0956-053X. Disponível em: ⟨https://www.sciencedirect.com/science/article/pii/S0956053X21002555⟩.

TABACHNICK, B. G.; FIDELL, L. S. *Using Multivariate Statistics*. 6. ed. New York: Harper and Row, 2012. ISBN 9780205849574.

VIDYAMURTHY, G. *Pairs Trading: Quantitative Methods and Analysis*. Hoboken: Wiley, 2004.

WANG, J. et al. A novel combination of pca and machine learning techniques to select the most important factors for predicting tunnel construction performance. *Buildings*, v. 12, n. 7, 2022. ISSN 2075-5309. Disponível em: ⟨https://www.mdpi.com/2075-5309/12/7/919⟩.

ZENG, Y.; LEE, B. S. Pushing the limit of pairs trading strategies. *Quantitative Finance*, v. 14, n. 10, p. 1783–1795, 2014.

10 Apêndices

A Construção dos Fatores por PCA

Neste apêndice apresentamos o código utilizado para estimar os fatores principais, conforme descrito na Seção 3.1. O algoritmo implementa a padronização das janelas, a decomposição da matriz de correlação e o cálculo dos retornos dos eigenportfólios.

```
# ==============================================================================
# Fatores PCA
# ==============================================================================

def compute_pca_factor_returns(returns: pd.DataFrame, window_pca: int = 60, n_fact
    """
    PCA: para cada t (a partir de window_pca),
    - padroniza janela [t-window_pca, t)
    - decompõe a correlação
    - monta pesos w_j = v_j / sigma_j (sigma da janela nos ativos válidos)
    - calcula F_j(t) = Rt · w_j usando retornos do próprio dia t

    Retorna
    -------
    DataFrame com colunas eig1..eig_m
    """
    dates = returns.index
    F = pd.DataFrame(index=dates, columns=[f"eig{i+1}" for i in range(n_factors)],

    for i in range(window_pca, len(dates)):
        t_hist = dates[i - window_pca : i]   # janela [t-60, t)
        t = dates[i]                         # data-alvo

        Rw = returns.loc[t_hist]
        Zw = padronizar_janela(Rw)
        Zw = Zw.dropna(axis=1, how='any')    # exclui colunas com NaN na janela
        Zw = Zw.dropna(axis=0, how='all')   # exclui linhas com NaN na janela

        if Zw.shape[1] < n_factors + 1:
```

```
            continue

        # PCA na correlação da janela
        _, evecs = decompor_corr(Zw)

        # std dos ativos válidos na janela, para construir w_j
        sigma_w = Rw.std(ddof=1)

        # retornos do dia t (precisamos de todos válidos nos ativos escolhidos)
        Rt = returns.loc[t, Zw.columns]
        if Rt.isnull().any():
            continue

        for j in range(n_factors):
            vj = pd.Series(evecs[:, j], index=Zw.columns)
            wj = normalizar_pesos(vj / sigma_w)
            F.loc[t, f"eig{j+1}"] = float(Rt.dot(wj))

    return F.dropna(how="all")
```

A figura a seguir mostra um exemplo real da saída gerada pela função: uma matriz em que cada linha corresponde a uma data e cada coluna representa o retorno de um dos m fatores extraídos pelo PCA.

```
factors_PCA = compute_pca_factor_returns(returns_full, window_pca = 60, n_factors = 15)
factors_PCA.head()
```

Date	eig1	eig2	eig3	eig4	eig5	eig6	eig7	eig8	eig9	eig10	eig11	eig12	eig13	eig14	eig15
1997-04-01	0.001253	0.002223	0.003196	-0.003016	-0.002674	-0.001467	-0.000481	-0.002293	0.000049	-0.001661	0.000128	-0.002116	-0.001282	0.000772	-0.001271
1997-04-02	-0.008550	0.000199	-0.001906	0.002043	0.001521	0.002194	-0.000792	0.000356	0.001829	-0.000181	0.002177	-0.000649	0.002101	-0.001211	0.002579
1997-04-03	-0.002928	-0.002436	-0.000341	0.001961	0.003974	-0.000904	-0.000104	-0.001693	-0.001765	-0.000800	0.002231	-0.000889	-0.000845	0.001140	0.000867
1997-04-04	-0.009413	-0.005957	-0.001595	-0.001454	-0.000686	-0.001885	-0.000184	0.000278	-0.000281	-0.000282	0.000169	0.000829	0.000842	-0.001896	-0.002742
1997-04-07	-0.007744	0.001269	-0.004531	0.000939	0.003507	-0.001301	0.000660	-0.003008	-0.000153	-0.000734	0.000121	0.000395	-0.000547	-0.000621	0.002984

B Processo de Ornstein–Uhlenbeck: cálculo e estimação dos parâmetros

Neste apêndice descrevemos, em maior detalhe, o procedimento utilizado para calibrar o processo de Ornstein–Uhlenbeck (O–U) que modela os desvios idiossincráticos $X_i(t)$ e para calcular os respectivos s-scores. Seguindo Avellaneda e Lee (AVELLANEDA; LEE, 2008), introduzimos um modelo paramétrico para o processo de desvios idiossincráticos $X_i(t)$, baseado no processo de Ornstein–Uhlenbeck (O–U):

$$dX_i(t) = \kappa_i\big(m_i - X_i(t)\big)\,dt + \sigma_i\,dW_i(t), \qquad \kappa_i > 0, \tag{23}$$

em que:

- m_i é o nível de equilíbrio de longo prazo do desvio idiossincrático;
- κ_i é a velocidade de reversão à média;
- σ_i é a intensidade dos choques idiossincráticos;
- $W_i(t)$ é um movimento browniano padrão.

Esse processo é gaussiano, markoviano e estacionário (para $\kappa_i > 0$), e sua versão em tempo discreto, amostrada em passos Δt, é autorregressiva de ordem 1 (modelo AR(1)). A seguir, derivamos explicitamente a solução geral de (23), bem como sua média e variância em equilíbrio.

Solução explícita da equação estocástica

Para simplificar a notação, omitimos o índice i e escrevemos

$$dX(t) = \kappa\big(m - X(t)\big)\,dt + \sigma\,dW(t), \qquad \kappa > 0.$$

Rearranjando os termos:

$$dX(t) + \kappa X(t)\,dt = \kappa m\,dt + \sigma\,dW(t).$$

Aplicamos o método do fator integrante, multiplicando ambos os lados por $e^{\kappa t}$:

$$e^{\kappa t}\,dX(t) + \kappa e^{\kappa t} X(t)\,dt = \kappa m e^{\kappa t}\,dt + \sigma e^{\kappa t}\,dW(t).$$

O lado esquerdo é a diferencial de $e^{\kappa t}X(t)$:

$$d\big(e^{\kappa t}X(t)\big) = \kappa m e^{\kappa t}\,dt + \sigma e^{\kappa t}\,dW(t).$$

Integramos entre um instante inicial t_0 e um instante futuro $t_0 + \Delta t$:

$$e^{\kappa(t_0+\Delta t)}X(t_0+\Delta t) - e^{\kappa t_0}X(t_0) = \int_{t_0}^{t_0+\Delta t} \kappa m e^{\kappa s}\,ds + \int_{t_0}^{t_0+\Delta t} \sigma e^{\kappa s}\,dW(s).$$

O primeiro integral é determinístico:

$$\int_{t_0}^{t_0+\Delta t} \kappa m e^{\kappa s}\,ds = \kappa m \cdot \frac{e^{\kappa s}}{\kappa}\Big|_{t_0}^{t_0+\Delta t} = m\big(e^{\kappa(t_0+\Delta t)} - e^{\kappa t_0}\big).$$

Substituindo e dividindo por $e^{\kappa(t_0+\Delta t)}$, obtemos:

$$X(t_0+\Delta t) = e^{-\kappa\Delta t}X(t_0) + m\big(1 - e^{-\kappa\Delta t}\big) + \sigma \int_{t_0}^{t_0+\Delta t} e^{-\kappa(t_0+\Delta t - s)}\,dW(s). \tag{24}$$

Essa é a solução geral do processo de Ornstein–Uhlenbeck, e coincide com a expressão apresentada por Avellaneda e Lee (AVELLANEDA; LEE, 2008): o estado futuro $X(t_0+\Delta t)$ é uma combinação exponencial do estado inicial $X(t_0)$, do nível de equilíbrio m e de um termo aleatório que é uma integral estocástica.

Média condicional e incondicional

A integral estocástica em (24) tem média condicional nula, dado $X(t_0)$, pois

$$\mathbb{E}\left[\int_{t_0}^{t_0+\Delta t} e^{-\kappa(t_0+\Delta t - s)}\,dW(s) \,\Big|\, X(t_0)\right] = 0.$$

Portanto, a média condicional de $X(t_0+\Delta t)$ dado $X(t_0)$ é

$$\mathbb{E}\big[X(t_0+\Delta t) \,\big|\, X(t_0)\big] = e^{-\kappa\Delta t}X(t_0) + m\big(1 - e^{-\kappa\Delta t}\big). \tag{25}$$

A partir dessa expressão, podemos interpretar o *drift* (tendência) do processo: quando $X(t_0) < m$, o termo $m - X(t_0)$ é positivo e a média condicional

puxa o processo para cima; quando $X(t_0) > m$, o processo tende a se mover, em média, para baixo. Em termos diferenciais, para um intervalo muito pequeno Δt, temos aproximadamente

$$\mathbb{E}\big[X(t_0 + \Delta t) - X(t_0) \,\big|\, X(t_0)\big] \approx \kappa\big(m - X(t_0)\big)\,\Delta t,$$

o que recupera a forma do drift na equação estocástica (23).

Se o processo estiver em regime estacionário, a média incondicional $\mathbb{E}[X(t)]$ deve ser constante no tempo. Fazendo $t_0 \to -\infty$ ou, equivalentemente, tomando o limite $\Delta t \to \infty$ em (25), observamos que

$$\lim_{\Delta t \to \infty} e^{-\kappa \Delta t} = 0,$$

e, portanto,

$$\lim_{\Delta t \to \infty} \mathbb{E}\big[X(t_0 + \Delta t) \,\big|\, X(t_0)\big] = m. \tag{26}$$

No equilíbrio estacionário, temos então

$$\mathbb{E}\big[X(t)\big] = m, \qquad \forall t. \tag{27}$$

Cálculo da variância e distribuição em equilíbrio

A variância condicional de $X(t_0 + \Delta t)$, dado $X(t_0)$, decorre novamente da expressão (24). Como o único termo aleatório é a integral estocástica e o processo é gaussiano, temos:

$$X(t_0 + \Delta t) \,\big|\, X(t_0) \sim \mathcal{N}\big(\mu(\Delta t),\, v(\Delta t)\big),$$

onde

$$\mu(\Delta t) = e^{-\kappa \Delta t} X(t_0) + m\big(1 - e^{-\kappa \Delta t}\big)$$

é a média condicional em (25), e

$$v(\Delta t) = \mathrm{Var}\left[\sigma \int_{t_0}^{t_0 + \Delta t} e^{-\kappa(t_0 + \Delta t - s)}\, dW(s)\right].$$

Utilizando a isometria de Itô, obtemos:

$$v(\Delta t) = \sigma^2 \int_{t_0}^{t_0 + \Delta t} e^{-2\kappa(t_0 + \Delta t - s)}\, ds.$$

Fazendo a mudança de variável $u = t_0 + \Delta t - s$, temos $du = -ds$ e, quando $s = t_0$, $u = \Delta t$; quando $s = t_0 + \Delta t$, $u = 0$. Logo:

$$\begin{aligned} v(\Delta t) &= \sigma^2 \int_0^{\Delta t} e^{-2\kappa u}\, du = \sigma^2 \left[-\frac{1}{2\kappa} e^{-2\kappa u} \right]_0^{\Delta t} \\ &= \sigma^2 \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \end{aligned}$$

Portanto,

$$\operatorname{Var}\big[X(t_0 + \Delta t) \,\big|\, X(t_0)\big] = \sigma^2 \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \tag{28}$$

No limite $\Delta t \to \infty$, o fator exponencial desaparece:

$$\lim_{\Delta t \to \infty} \left(1 - e^{-2\kappa \Delta t}\right) = 1,$$

e obtemos a variância em equilíbrio:

$$\operatorname{Var}\big[X(t)\big] = \lim_{\Delta t \to \infty} v(\Delta t) = \frac{\sigma^2}{2\kappa}. \tag{29}$$

Combinando (27) e (29), concluímos que a distribuição estacionária de $X(t)$ é normal:

$$X(t) \overset{d}{\sim} \mathcal{N}\left(m, \frac{\sigma^2}{2\kappa}\right), \qquad t \text{ em equilíbrio.}$$

Definindo o desvio-padrão estacionário como

$$\sigma_{\text{eq}} = \sqrt{\frac{\sigma^2}{2\kappa}}, \tag{30}$$

que é exatamente a forma utilizada no cálculo do s-score na Seção 5.1. Essa caracterização coincide com a encontrada por Avellaneda e Lee (AVELLANEDA; LEE, 2008) ao considerar o limite de longo prazo $\Delta t \to \infty$ na solução do processo de Ornstein–Uhlenbeck.

B.1 Discretização em tempo e modelo AR(1)

Na prática, não observamos $X_i(t)$ em tempo contínuo, mas sim uma sequência de resíduos diários de regressão, denotados por ε_n, $n = 1, \ldots, L$, obtidos

a partir da decomposição multifatorial em janelas móveis de comprimento 60. Seguindo Avellaneda e Lee (AVELLANEDA; LEE, 2008), construímos o processo acumulado discreto

$$X_k = \sum_{j=1}^{k} \varepsilon_j, \qquad k = 1, \dots, L, \tag{31}$$

que pode ser interpretado como uma versão discretizada do processo contínuo $X(t)$ em instantes igualmente espaçados $(t_0, t_0 + \Delta t, t_0 + 2\Delta t, \dots)$, com $\Delta t = 1/252$ ano.

Partindo da equação estocástica em tempo contínuo,

$$dX(t) = \kappa\big(m - X(t)\big)\, dt + \sigma\, dW(t),$$

a solução explícita em um intervalo de comprimento Δt, obtida na equação 24, pode ser escrita como

$$X(t + \Delta t) = e^{-\kappa \Delta t} X(t) + m\big(1 - e^{-\kappa \Delta t}\big) + \sigma \int_t^{t+\Delta t} e^{-\kappa(t+\Delta t - s)}\, dW(s). \tag{32}$$

Se definirmos os instantes discretos $t_n = t_0 + n\,\Delta t$ e escrevermos $X_n := X(t_n)$, a expressão acima torna-se

$$X_{n+1} = e^{-\kappa \Delta t} X_n + m\big(1 - e^{-\kappa \Delta t}\big) + \sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1} - s)}\, dW(s). \tag{33}$$

Comparando (33) com um modelo autorregressivo de ordem 1 (AR(1)),

$$X_{n+1} = a + b\, X_n + \zeta_{n+1}, \qquad n = 1, \dots, L - 1, \tag{34}$$

vemos que a identificação é imediata:

$$b = e^{-\kappa \Delta t}, \tag{35}$$

$$a = m\big(1 - e^{-\kappa \Delta t}\big) = m(1 - b), \tag{36}$$

$$\zeta_{n+1} = \sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1} - s)}\, dW(s). \tag{37}$$

Por construção, o termo ζ_{n+1} tem média condicional zero dado X_n, pois se trata de uma integral estocástica com integrando determinístico. Resta,

então, calcular sua variância. Aplicando a isometria de Itô à definição (37), obtemos:

$$\begin{aligned}\mathrm{Var}(\zeta) &= \mathrm{Var}\left[\sigma \int_{t_n}^{t_{n+1}} e^{-\kappa(t_{n+1}-s)}\, dW(s)\right] \\ &= \sigma^2 \int_{t_n}^{t_{n+1}} e^{-2\kappa(t_{n+1}-s)}\, ds. \end{aligned} \tag{38}$$

Fazendo a mudança de variável $u = t_{n+1} - s$, de modo que $ds = -du$, obtemos:

$$\begin{aligned}\mathrm{Var}(\zeta) &= \sigma^2 \int_0^{\Delta t} e^{-2\kappa u}\, du \\ &= \sigma^2 \left[-\frac{1}{2\kappa} e^{-2\kappa u}\right]_0^{\Delta t} \\ &= \sigma^2\, \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \end{aligned} \tag{39}$$

Assim, a relação entre os parâmetros discretos $(a, b, \mathrm{Var}(\zeta))$ do modelo AR(1) e os parâmetros contínuos (m, κ, σ) do processo de Ornstein–Uhlenbeck é dada por:

$$b = e^{-\kappa \Delta t}, \tag{40}$$

$$a = m\big(1 - e^{-\kappa \Delta t}\big) = m(1 - b), \tag{41}$$

$$\mathrm{Var}(\zeta) = \sigma^2\, \frac{1 - e^{-2\kappa \Delta t}}{2\kappa}. \tag{42}$$

A partir dessas expressões, obtemos as fórmulas inversas de estimação:

$$\kappa = -\frac{1}{\Delta t}\, \log(b), \tag{43}$$

$$m = \frac{a}{1 - b}, \tag{44}$$

$$\sigma = \sqrt{\mathrm{Var}(\zeta)\, \frac{2\kappa}{1 - b^2}}. \tag{45}$$

Por convenção, utilizamos $\Delta t = 1/252$ e reportamos a velocidade de reversão em termos anualizados:

$$\kappa_{\mathrm{ann}} = -\log(b) \cdot 252. \tag{46}$$

Por fim, substituindo (42) na expressão da variância estacionária do processo discreto, obtemos uma forma particularmente simples para o desvio-padrão de equilíbrio σ_{eq} diretamente em função de b e $\text{Var}(\zeta)$:

$$\sigma_{\text{eq}} = \sqrt{\frac{\text{Var}(\zeta)}{1 - b^2}}. \tag{47}$$

B.2 Implementação numérica

A seguir, apresentamos a função em Python utilizada para estimar, em cada janela temporal, os parâmetros do processo O–U a partir da sequência de resíduos $\{\varepsilon_n\}$. A função implementa exatamente o procedimento descrito nas subseções anteriores: constrói o passeio acumulado X_k, ajusta o modelo AR(1), recupera $\hat{m}$, $\hat{\kappa}_{\text{ann}}$, $\text{Var}(\zeta)$ e $\hat{\sigma}_{\text{eq}}$, e retorna também o estado atual do processo X_T.

Função de estimação do processo O–U em Python

```
def estimate_ou_from_cumsum(epsilon):
    """
    Estima um processo de Ornstein-Uhlenbeck a partir do
    passeio acumulado X_k = sum_{j<=k} epsilon_j.

    Modelo discreto (AR(1)):
        X_{n+1} = a + b * X_n + zeta_{n+1}

    Retorna:
        m, X_T, var_zeta, kappa_ann, sigma_eq

    Onde:
      - kappa_ann = -log(b) * 252
      - sigma_eq  = sqrt( var_zeta / (1 - b**2) )
      - m         = a / (1 - b)              (nível de equilíbrio)
      - X_T       = X_ultimo = sum(epsilon)  (estado atual do processo)
    """
    # checagens básicas
    eps = np.asarray(epsilon, dtype=float)
    if eps.ndim != 1:
        eps = eps.ravel()
```

```
if len(eps) < 2 or not np.isfinite(eps).all():
    return None

# passeio acumulado X_k
Xk = np.cumsum(eps)
if len(Xk) < 2:
    return None

# regressão 1-lag: X_{n+1} = a + b X_n + zeta_{n+1}
X_ou = Xk[:-1].reshape(-1, 1)
y_ou = Xk[1:]

model = LinearRegression().fit(X_ou, y_ou)
a = float(model.intercept_)
b = float(model.coef_[0])

# checando os parâmetros
if not np.isfinite(a) or not np.isfinite(b) or not (1e-6 < b < 0.999):
    return None

# ruído e variância do choque zeta
zeta = y_ou - model.predict(X_ou)
var_zeta = float(np.var(zeta, ddof=1))
if not np.isfinite(var_zeta) or var_zeta <= 0:
    return None

# nível de equilíbrio m, kappa anualizado e sigma no equilíbrio
m = a / (1.0 - b)
kappa_ann = -np.log(b) * float(252)
sigma_eq = np.sqrt(var_zeta / (1.0 - b**2))

# estado atual do processo: X_T
X_T = float(Xk[-1])

return m, X_T, var_zeta, kappa_ann, sigma_eq
```

Essa rotina é aplicada de forma sistemática às janelas móveis de resíduos

para cada ativo da amostra, produzindo séries temporais de parâmetros

$$\left(\hat{m}_i(t),\, \widehat{\mathrm{Var}(\zeta_i)}(t),\, \hat{\kappa}_{i,\mathrm{ann}}(t),\, \hat{\sigma}_{i,\mathrm{eq}}(t)\right)$$

e de estados $X_i(t)$. Esses objetos alimentam diretamente o cálculo dos s-scores e, consequentemente, a geração dos sinais de trading descritos na Seção 5.